

Avaliação de Classificadores e Regressão Logística

Mineração de Dados

Helton Graziadei

O caso binário: revisão

Em um problema de classificação, $Y \in \mathcal{C}$ é uma v.a. categórica. No caso binário, $\mathcal{C} = \{0, 1\}$, definimos

$$\eta(\mathbf{x}) := \mathbb{P}(Y = 1 \mid X = \mathbf{x})$$

- Risco sob perda 0–1: $R(\varphi) = \mathbb{P}(Y \neq \varphi(X))$.
- Vimos que o risco é minimizado pelo classificador de Bayes:

$$\varphi(\mathbf{x}) = \mathbb{I}(\eta(\mathbf{x}) \geq \tfrac{1}{2}) = \begin{cases} 1, & \text{se } \eta(\mathbf{x}) \geq 1/2, \\ 0, & \text{c.c.} \end{cases}$$

- Como não conhecemos η , usamos um estimador $\hat{\eta}$ e o classificador plug-in:

$$\hat{\varphi}(\mathbf{x}) = \mathbb{I}(\hat{\eta}(\mathbf{x}) \geq \tfrac{1}{2}).$$

Duas perguntas

- (i) Como estimar $\varphi(\mathbf{x})$ via regressão logística?
- (ii) Como avaliar a qualidade de um classificador $\hat{\varphi}$?

Do classificador plug-in à regressão logística

No caso binário, o classificador de Bayes é $\varphi(\mathbf{x}) = \mathbb{I}(\eta(\mathbf{x}) \geq 1/2)$. Na abordagem plug-in, precisamos estimar η para obter a regra de classificação estimada.

Por que não usar regressão linear diretamente?

$$\eta(\mathbf{x}; \boldsymbol{\beta}) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

- Pode produzir valores < 0 ou > 1 .
- Não respeita a restrição $\eta(\mathbf{x}; \boldsymbol{\beta}) \in [0, 1]$.

Solução: aplicar uma função de ligação que leve $(0, 1)$ em $\mathbb{R}$, a ligação *logito*.

(Lembrete: não acreditamos que o modelo logístico seja *verdadeiro*; apenas que ele produz um bom $\hat{\varphi}$.)

Definição

A **regressão logística** assume

$$\eta(\mathbf{x}; \boldsymbol{\beta}) = P(Y = 1 \mid \mathbf{x}) = \frac{e^{\mathbf{x}^\top \boldsymbol{\beta}}}{1 + e^{\mathbf{x}^\top \boldsymbol{\beta}}}.$$

Equivalentemente, em termos de *log-chances* (logito):

$$\log\left(\frac{\eta(\mathbf{x}; \boldsymbol{\beta})}{1 - \eta(\mathbf{x}; \boldsymbol{\beta})}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

- O logito é linear nas covariáveis.
- β_j : efeito de x_j na log-chance, mantendo as demais fixas.

Estimação: máxima verossimilhança

Dada amostra de treinamento i.i.d. $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$, a função de verossimilhança é

$$L(\beta) = \prod_{i=1}^n \left(\frac{e^{\mathbf{x}_i^\top \beta}}{1 + e^{\mathbf{x}_i^\top \beta}} \right)^{y_i} \left(\frac{1}{1 + e^{\mathbf{x}_i^\top \beta}} \right)^{1-y_i}.$$

Log-verossimilhança:

$$\ell(\beta) = \sum_{i=1}^n \left[y_i \log \left(\frac{e^{\mathbf{x}_i^\top \beta}}{1 + e^{\mathbf{x}_i^\top \beta}} \right) + (1 - y_i) \log \left(\frac{1}{1 + e^{\mathbf{x}_i^\top \beta}} \right) \right].$$

- $\hat{\beta} = \arg \max_{\beta} \ell(\beta)$.
- Sem forma fechada: usa-se otimização iterativa (Newton-Raphson).
- ℓ é **côncava** $\Rightarrow$ máximo global.

Interpretando os coeficientes

Tomando o logito do modelo logístico,

$$\log\left(\frac{\eta(\mathbf{x}; \boldsymbol{\beta})}{1 - \eta(\mathbf{x}; \boldsymbol{\beta})}\right) = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p.$$

Considere duas amostras que diferem **apenas** em x_j (uma unidade a mais), mantendo as demais fixas. Subtraindo os logitos,

$$\log\left(\frac{\text{chance}(x_j + 1)}{\text{chance}(x_j)}\right) = \beta_j \implies \frac{\text{chance}(x_j + 1)}{\text{chance}(x_j)} = e^{\beta_j}.$$

Interpretação

Um aumento de uma unidade em x_j (demais fixas) multiplica a chance de $Y = 1$ por e^{β_j} .
Equivalentemente, e^{β_j} é a razão de chances..

$\beta_j > 0 \Rightarrow e^{\beta_j} > 1$ (chance aumenta);

$\beta_j = 0 \Rightarrow e^{\beta_j} = 1$ (sem efeito);

$\beta_j < 0 \Rightarrow e^{\beta_j} < 1$ (chance diminui).

Regularização na regressão logística

Em altas dimensões (p grande), MV tende a ter alta variância ou não convergir.
Solução: penalizar a log-verossimilhança.

Logística com penalização Lasso

$$\hat{\beta} = \arg \min_{\beta} \{-\ell(\beta) + \lambda \|\beta\|_1\}$$

- λ escolhido por validação cruzada.
- No R: `glmnet(x, y, family = "binomial", alpha = 1)`.

Por que a acurácia não basta?

Suponha que, em uma amostra i.i.d., apenas 1% das observações pertencem a classe 1. O classificador trivial $\tilde{\varphi}(\mathbf{x}) \equiv 0$ tem acurácia de 99%. Mas nenhum doente é identificado!

- Em dados desbalanceados, a acurácia esconde o desempenho por classe.
- Precisamos distinguir os tipos de erro:
 - **Falso positivo (FP)**: classificar um não-doente como doente.
 - **Falso negativo (FN)**: classificar um doente como não-doente.

Matriz de confusão

Compara-se, no conjunto de teste, o real Y com o predito $\hat{\varphi}(\mathbf{x})$:

	$Y = 0$	$Y = 1$
$\hat{\varphi} = 0$	TN	FN
$\hat{\varphi} = 1$	FP	TP

- $TP + FN =$ total de positivos reais; $TN + FP =$ total de negativos reais.
- Risco estimado: $\hat{R}(\hat{\varphi}) = (FP + FN)/(TP + TN + FN + FP)$.
- Calcular TP, FN, TN, FP sempre em uma amostra separada daquela utilizada para construir o classificador

Sensibilidade (S) — taxa de verdadeiros positivos

$$S = \frac{TP}{TP + FN}$$

Dos pacientes doentes, quantos foram corretamente classificados?

Especificidade (E) — taxa de verdadeiros negativos

$$E = \frac{TN}{TN + FP}$$

Dos pacientes não doentes, quantos foram corretamente classificados?

Classificador trivial $\hat{\phi} \equiv 0$: $S = 0$ e $E = 1$. Especificidade alta, sensibilidade zero (classificador ruim).

Obs.: em geral $S + E \neq 1$.

O papel do limiar (*threshold*)


No caso binário, o classificador plug-in com limiar $K \in [0, 1]$ é

$$\hat{\varphi}_K(\mathbf{x}) = \mathbb{I}(\hat{\eta}(\mathbf{x}) \geq K)$$

- Quando $Y = 1$ é *raro*, $\eta(\mathbf{x})$ é tipicamente baixo em todo $\mathbf{x}$: usar $K = 1/2$ leva a classificar sempre $Y = 0$, mesmo se η estiver bem estimada.
- Solução: buscar cortes K diferentes de $1/2$.
- Variar $K \in [0, 1]$ *muda* a matriz de confusão:
 - $K \downarrow 0$: $S \rightarrow 1$, $E \rightarrow 0$ (quase tudo positivo).
 - $K \uparrow 1$: $S \rightarrow 0$, $E \rightarrow 1$ (quase tudo negativo).

Curva ROC e AUC

- Para cada K , calcula-se o par $(1 - E(K), S(K))$.
- A **curva ROC** é o lugar geométrico desses pares.
- É comum escolher K^* que maximiza $S(K) + E(K)$.
- **AUC** $\in [0, 1]$: área sob a curva.
 - AUC = 1: classificador perfeito.
 - AUC = 0,5: aleatório (diagonal).
- Interpretação: probabilidade de, dado um positivo e um negativo aleatórios, $\hat{\varphi}_K$ do positivo exceder o do negativo.



Ajuste no R

```
library(pROC)
# Ajuste básico: estima  $\eta(x) = P(Y=1|x)$ 
ajuste <- glm(y ~ ., data = treino, family = binomial)
eta_hat <- predict(ajuste, newdata = teste, type = "response")

# Classificador plug-in com corte K (phi_hat)
K <- 0.5
phi_hat <- ifelse(eta_hat >= K, 1, 0)
table(real = teste$y, predito = phi_hat)      # matriz de confusão

# Curva ROC e AUC
roc_obj <- roc(teste$y, phi_hat)
auc(roc_obj)
plot(roc_obj,
     col = "blue", grid = TRUE,
     legacy.axes = TRUE, asp = FALSE, las = 1,
     print.thres.pattern = "%.3f",
     print.thres = "best")
```

E quando há várias categorias?

Quando $\mathcal{C} = \{0, 1, \dots, K - 1\}$ com $K > 2$, definimos, para cada classe c ,

$$\eta_c(\mathbf{x}) := \mathbb{P}(Y = c \mid X = \mathbf{x})$$

e o classificador de Bayes (que continua minimizando o risco) passa a ser

$$\varphi(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \eta_c(\mathbf{x}),$$

Estratégia plug-in:

$$\hat{\varphi}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \hat{\eta}_c(\mathbf{x}),$$

Não estamos supondo que o modelo usado seja *verdadeiro*; basta que produza $\hat{\varphi}_c \approx \varphi_c$ razoável para induzir um bom classificador.

Caso multiclasse: uma logística por classe

Para $\mathcal{C} = \{1, \dots, K\}$, ajustamos K regressões logísticas: para cada c , estimamos $\hat{\psi}_c(\mathbf{x})$ usando $Z_c = \mathbb{I}(Y = c)$ como resposta binária. O classificador é

$$\hat{\varphi}(\mathbf{x}) = \arg \max_{c \in \mathcal{C}} \hat{\eta}_c(\mathbf{x}).$$

Alternativa — regressão logística multinomial:

$$\hat{\eta}_c(\mathbf{x}) = \frac{e^{\hat{\beta}_{0,c} + \mathbf{x}^\top \hat{\beta}_c}}{\sum_{s=1}^K e^{\hat{\beta}_{0,s} + \mathbf{x}^\top \hat{\beta}_s}}, \quad c = 1, \dots, K,$$

que garante $\sum_c \hat{\eta}_c(\mathbf{x}) = 1$.

Do logito binário ao multiclasse

Caso binário. Com $\mathcal{C} = \{0, 1\}$, o modelo logístico é equivalente a

$$\log\left(\frac{\eta_1(\mathbf{x})}{\eta_0(\mathbf{x})}\right) = \mathbf{x}^\top \boldsymbol{\beta}, \quad \eta_0(\mathbf{x}) = 1 - \eta_1(\mathbf{x}).$$

Ideia natural para K classes. Fixar uma classe de referência (digamos $c = 0$) e modelar cada log-razão:

$$\log\left(\frac{\eta_c(\mathbf{x})}{\eta_0(\mathbf{x})}\right) = \mathbf{x}^\top \boldsymbol{\beta}_c, \quad c = 1, \dots, K - 1.$$

Exponenciando: $\eta_c(\mathbf{x}) = \eta_0(\mathbf{x}) e^{\mathbf{x}^\top \boldsymbol{\beta}_c}$. Como $\sum_{c=0}^{K-1} \eta_c(\mathbf{x}) = 1$,

$$\eta_0(\mathbf{x}) \left(1 + \sum_{c=1}^{K-1} e^{\mathbf{x}^\top \boldsymbol{\beta}_c} \right) = 1.$$

Regressão multinomial

Resolvendo para η_0 e substituindo de volta:

$$\eta_0(\mathbf{x}) = \frac{1}{1 + \sum_{s=1}^{K-1} e^{\mathbf{x}^\top \beta_s}}, \quad \eta_c(\mathbf{x}) = \frac{e^{\mathbf{x}^\top \beta_c}}{1 + \sum_{s=1}^{K-1} e^{\mathbf{x}^\top \beta_s}}.$$

Definindo $\beta_0 \equiv 0$,

$$\eta_c(\mathbf{x}) = \frac{e^{\mathbf{x}^\top \beta_c}}{\sum_{s=0}^{K-1} e^{\mathbf{x}^\top \beta_s}}, \quad c = 0, 1, \dots, K-1.$$

- Sem a restrição $\beta_0 \equiv 0$, somar um vetor comum a todos os β_s não altera $\eta_c(\mathbf{x})$ — o modelo seria superparametrizado.
- $K = 2$ recupera a logística binária com $\beta = \beta_1$.

Regressão multinomial

Para $Y_i \in \{0, \dots, K-1\}$, use a codificação: $z_{ic} = \mathbb{I}(y_i = c)$, com $\sum_c z_{ic} = 1$. Cada observação é Multinomial($1; \eta_0(\mathbf{x}_i), \dots, \eta_{K-1}(\mathbf{x}_i)$):

$$L(\beta_1, \dots, \beta_{K-1}) = \prod_{i=1}^n \prod_{c=0}^{K-1} \eta_c(\mathbf{x}_i)^{z_{ic}}.$$

Log-verossimilhança:

$$\ell(\beta_1, \dots, \beta_{K-1}) = \sum_{i=1}^n \left[\sum_{c=1}^{K-1} z_{ic} \mathbf{x}_i^\top \beta_c - \log \left(\sum_{s=0}^{K-1} e^{\mathbf{x}_i^\top \beta_s} \right) \right].$$

Concavidade: $\log \sum_s e^{\mathbf{x}_i^\top \beta_s}$ é convexa em $(\beta_1, \dots, \beta_{K-1})$ (log-sum-exp é convexa), e o primeiro termo é linear em cada $\beta_c \Rightarrow \ell$ é côncava $\Rightarrow$ máximo global.

“One-vs-all” $\neq$ Multinomial

As duas abordagens multiclasse vistas **não são equivalentes**:

K logísticas binárias

- Ajusta K modelos independentes com $Z_c = \mathbb{I}(Y = c)$.
- $\sum_c \hat{\eta}_c(\mathbf{x}) \neq 1$ em geral.
- Simples; útil quando K é grande.
- Ignora a restrição de soma: estimadores menos eficientes.

Multinomial

- Ajusta $K - 1$ vetores β_c *conjuntamente*.
- $\sum_c \hat{\eta}_c(\mathbf{x}) = 1$ por construção.
- MLE sob o modelo multinomial *verdadeiro*.
- `glmnet(family="multinomial")`.

Em ambos os casos, a regra plug-in é $\hat{\varphi}(\mathbf{x}) = \arg \max_c \hat{\eta}_c(\mathbf{x})$. Para decisão, o que importa é a *ordenação* das probabilidades, não sua normalização — por isso one-vs-all costuma funcionar razoavelmente bem na prática.

- Plug-in binário: estime η por qualquer método de regressão; classifique por $\hat{\phi}(\mathbf{x}) = \mathbb{I}(\hat{\eta}(\mathbf{x}) \geq 1/2)$.
- A taxa de erro pode ser enganosa em dados desbalanceados.
- A matriz de confusão decompõe erros em FP e FN, dando origem a:
 - Sensibilidade, especificidade (curva ROC/AUC).
- O limiar K deve ser escolhido com cuidado em dados desbalanceados.
- Regressão logística: modela $\eta(\mathbf{x})$ via função logito.
- Estimação por máxima verossimilhança (log-verossimilhança côncava).
- Versões penalizadas (*lasso*, *ridge*) são essenciais em altas dimensões.
- Extensão multiclasse: $\hat{\phi}(\mathbf{x}) = \arg \max_c \hat{\psi}_c(\mathbf{x})$ via K logísticas ou modelo multinomial.