

Lista de Exercícios III

Avaliação de classificadores e regressão logística

Exercício 1. Em um estudo para detecção precoce de uma doença rara, um classificador $\hat{\varphi}$ foi avaliado em um conjunto de teste com $n = 1000$ pacientes. A matriz de confusão obtida foi:

	$Y = 0$	$Y = 1$	Total
$\hat{\varphi} = 0$	880	30	910
$\hat{\varphi} = 1$	50	40	90
Total	930	70	1000

Em aula, definimos sensibilidade (S) e especificidade (E). Vamos agora introduzir duas medidas adicionais que são particularmente úteis em dados desbalanceados. O **valor preditivo positivo** (VPP), também chamado de *precisão*, é definido por

$$\text{VPP} = \frac{\text{TP}}{\text{TP} + \text{FP}},$$

e responde à pergunta: *dentre os classificados como positivos, qual a fração realmente positiva?* Enquanto que a sensibilidade condicional no rótulo verdadeiro, o VPP condicional na predição obtida pelo classificador. A **estatística F_1** é definida como

$$F_1 = \frac{2 \cdot \text{VPP} \cdot S}{\text{VPP} + S}.$$

Responda às perguntas:

- Calcule a acurácia, a sensibilidade S , a especificidade E , o VPP e a estatística F_1 para este classificador.
- Considere o classificador trivial $\tilde{\varphi} \equiv 0$ aplicado ao mesmo conjunto de teste. Calcule sua acurácia. Em seguida, calcule sua sensibilidade S e seu F_1 (use a convenção de que $F_1 = 0$ quando $\text{TP} = 0$). Comente: por que, em dados desbalanceados, o F_1 é uma medida mais informativa que a acurácia?
- Mostre que a estatística F_1 é a *média harmônica* entre VPP e S . Lembre que, dados $a, b > 0$, a média harmônica é

$$H(a, b) = \frac{2}{\frac{1}{a} + \frac{1}{b}}.$$

- Um resultado conhecido estabelece que

$$H(a, b) \leq \sqrt{ab} \leq \frac{a + b}{2},$$

ou seja, a média harmônica é dominada pela média geométrica, que por sua vez é dominada pela média aritmética. Use este fato para argumentar por que o F_1 *penaliza* fortemente classificadores com VPP e S muito desbalanceados (por exemplo, VPP alto e S baixo).

Exercício 2. Em um hospital, um teste rápido para uma infecção foi aplicado a 500 pacientes, resultando em $\text{TP} = 45$, $\text{FN} = 15$, $\text{FP} = 40$ e $\text{TN} = 400$.

- Monte a matriz de confusão e calcule acurácia, sensibilidade, especificidade, VPP e F_1 .

A **prevalência** de uma condição em uma população é a proporção de indivíduos que possuem a condição em um dado momento. Em uma amostra com rótulos $Y \in \{0, 1\}$ (onde $Y = 1$ indica presença da condição), a prevalência observada é $\frac{TP+FN}{TP+FN+FP+TN}$.

- (b) Calcule a prevalência observada da infecção no conjunto de teste.
- (c) Um classificador trivial que declara todos como não infectados teria qual acurácia? Qual seria sua sensibilidade? Comente a comparação.

Exercício 3. Considere 6 observações de teste com respostas observadas y e probabilidades preditas $\hat{\eta}(\mathbf{x})$ obtidas por um modelo de regressão logística:

i	1	2	3	4	5	6
y_i	0	0	1	0	1	1
$\hat{\eta}(\mathbf{x}_i)$	0,15	0,28	0,42	0,55	0,70	0,88

- (a) Para cada limiar $K \in \{0,10, 0,30, 0,50, 0,65, 0,80, 0,95\}$, calcule $S(K)$ e $1 - E(K)$.
- (b) Esboce a curva ROC.
- (c) Qual limiar $K^* \in \{0,10, \dots, 0,95\}$ maximiza $S(K) + E(K)$?

Exercício 4. No modelo de regressão logística com $\eta(\mathbf{x}) = \sigma(\beta_0 + \beta_1 x_1 + \dots + \beta_p x_p)$, onde $\sigma(t) = e^t / (1 + e^t)$, mostre que:

- (a) Se x_j aumenta em 1 unidade (com as demais covariáveis fixas), a razão de chances (*odds ratio*) fica multiplicada por e^{β_j} .
- (b) Se $\beta_j = 0$, a covariável x_j não afeta $\eta(\mathbf{x})$.
- (c) A derivada $\partial\eta/\partial x_j = \beta_j \eta(\mathbf{x})(1 - \eta(\mathbf{x}))$. Contraste este resultado com o modelo de regressão linear clássico, interpretando como a localização do vetor $\mathbf{x}$ afeta o impacto da covariável na probabilidade modelada.

Exercício 5. O conjunto de dados `Default` do pacote `ISLR2` contém informações sobre 10 000 clientes, incluindo a variável resposta `default` (cliente entrou em inadimplência: **Yes/No**) e covariáveis `student`, `balance` e `income`.

- (a) Carregue os dados, codifique `default` como variável binária $Y \in \{0, 1\}$ e divida a amostra em treino (70%) e teste (30%) usando `set.seed(2025)`.
- (b) Ajuste uma regressão logística com penalização Lasso usando `glmnet` com `family = "binomial"` e `alpha = 1`. Selecione λ por validação cruzada com `cv.glmnet`. Reporte $\lambda_{\min}$ e λ_{1se} e compare os coeficientes selecionados em cada caso.
- (c) Avalie o desempenho do modelo selecionado por λ_{1se} no conjunto de teste, usando $K = 0,5$. Reporte a matriz de confusão, a acurácia, S , E , VPP e F_1 .
- (d) Trace a curva ROC no conjunto de teste e calcule a AUC (use `pROC::roc`). Determine o limiar ótimo pelo critério de Youden.