

Seleção de Variáveis e Regularização

Mineração de Dados

Helton Graziadei

Considere que ajustamos um modelo de regressão linear com p covariáveis:

$$\hat{\psi}(\mathbf{x}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p.$$

Problema: nem todas as p covariáveis contribuem efetivamente para a predição.

Por que selecionar variáveis?

- Redução de variância: remover preditores irrelevantes diminui a variância de $\hat{\psi}$, podendo reduzir o risco.
- Interpretabilidade: modelos mais enxutos são mais fáceis de comunicar.
- Custo: na prática, coletar dados pode ser caro. Menos variáveis = menor custo.


Dado o conjunto de preditores $\{x_1, x_2, \dots, x_p\}$, queremos encontrar o subconjunto $\mathcal{S} \subseteq \{1, \dots, p\}$ tal que o modelo

$$\hat{\psi}_{\mathcal{S}}(\mathbf{x}) = \hat{\beta}_0 + \sum_{j \in \mathcal{S}} \hat{\beta}_j x_j$$


tenha o menor erro de teste esperado (risco) possível.

Dificuldade: existem 2^p subconjuntos possíveis.

- $p = 10$: $2^{10} = 1\,024$ modelos.
- $p = 20$: $2^{20} \approx 1$ milhão de modelos.
- $p = 40$: $2^{40} \approx 1$ trilhão de modelos!



Motivação



⇒ Precisamos de estratégias computacionalmente viáveis.

Best Subset Selection

Ideia: avaliar *todos* os 2^p subconjuntos de preditores.

Algoritmo:

1. Para cada $k \in \{0, 1, \dots, p\}$, ajustar todos os $\binom{p}{k}$ modelos com exatamente k preditores.
2. Dentre os modelos com k preditores, selecionar o que tem menor EQM_{treino} . Chamar de $\hat{\psi}^{(k)}$.
3. Dentre $\hat{\psi}^{(0)}, \hat{\psi}^{(1)}, \dots, \hat{\psi}^{(p)}$, escolher o melhor via validação cruzada ou critério de informação (AIC, BIC).

Atenção: não podemos comparar os $\hat{\psi}^{(k)}$ pelo EQM de treino diretamente, pois o EQM sempre diminui ao acrescentar variáveis.

Limitações do Best Subset Selection

- Custo computacional: 2^p modelos crescem exponencialmente. Na prática, viável apenas para $p \lesssim 30\text{--}40$.
- Problemas estatísticos: com muitos modelos candidatos, há maior risco de *overfitting* no próprio processo de seleção. O EQM de teste de cada modelo individual é uma estimativa não viesada do risco verdadeiro, mas o mínimo entre muitas estimativas não-enviesadas é enviesado para baixo.
- Em grandes dimensões, precisamos de abordagens mais eficientes.

⇒ Alternativas: *forward* e *backward stepwise selection*.

Observação: seleção para modelos não paramétricos

A seleção de variáveis não se restringe a modelos lineares!

Podemos aplicar seleção de variáveis usando qualquer método preditivo como base (ex.: kNN, árvores de regressão, florestas aleatórias).

O critério de seleção em cada passo é o mesmo: estimar o risco do modelo com e sem cada variável (via validação cruzada) e escolher a melhor ação.

A seleção de variáveis é uma estratégia **agnóstica** ao modelo. O que muda é o modelo ajustado em cada subconjunto; a lógica de busca (forward, backward) permanece a mesma.

Forward Stepwise Selection

Ideia: começar com o modelo nulo e adicionar preditores um a um.

Algoritmo:

1. Começar com $\hat{\psi}^{(0)}$: modelo sem preditores (apenas o intercepto $\hat{\beta}_0$).
2. Para $k = 0, 1, \dots, p - 1$:
 - Considerar os $p - k$ modelos que acrescentam uma variável a $\hat{\psi}^{(k)}$.
 - Escolher o modelo com menor *EQM*. Chamar de $\hat{\psi}^{(k+1)}$.
3. Dentre $\hat{\psi}^{(0)}, \hat{\psi}^{(1)}, \dots, \hat{\psi}^{(p)}$, selecionar o melhor via validação cruzada ou critério de informação.

Custo: $1 + p + (p - 1) + \dots + 1 = 1 + p(p + 1)/2$ modelos.

Para $p = 20$: apenas 211 modelos, contra 1 048 576 do best subset.

Backward Stepwise Selection

Ideia: começar com o modelo completo e remover preditores um a um.

Algoritmo:

1. Começar com $\hat{\psi}^{(p)}$: modelo com todos os p preditores.
2. Para $k = p, p - 1, \dots, 1$:
 - Considerar os k modelos que removem uma variável de $\hat{\psi}^{(k)}$.
 - Escolher o modelo com menor EQM . Chamar de $\hat{\psi}^{(k-1)}$.
3. Dentre $\hat{\psi}^{(0)}, \hat{\psi}^{(1)}, \dots, \hat{\psi}^{(p)}$, selecionar o melhor via critério de informação (AIC ou BIC) ou validação cruzada.

Custo computacional: mesmo que forward, $1 + p(p + 1)/2$ modelos.

Restrição: requer $n > p$ (para que o modelo completo seja estimável).

Comparação das estratégias

Best Subset

Modelos: 2^p

Viável: $p \lesssim 30$

Forward

Modelos: $\sim p^2/2$

Viável: p grande

Backward

Modelos: $\sim p^2/2$

Requer: $n > p$

Forward e *backward* são algoritmos heurísticos; não exploram todo o espaço, então podem não encontrar o melhor subconjunto. Ainda assim, costumam funcionar bem na prática.

Escolhendo o número de variáveis

Os três métodos produzem uma sequência de modelos $\hat{\psi}^{(0)}, \hat{\psi}^{(1)}, \dots, \hat{\psi}^{(p)}$.

Para escolher o número ótimo de variáveis k^* :

Ajuste do EQM de treino (penalização pela complexidade):

- AIC: $\text{AIC} = -2 \log L + 2k$.
- BIC: $\text{BIC} = -2 \log L + k \log n$.

Sob a ótica preditivista, a validação cruzada é geralmente preferida: ela estima diretamente o risco de predição sem depender de suposições sobre o modelo.

Estimação direta do risco:

- Validação cruzada (k -fold CV).
- Data splitting.

Formulação via penalização ℓ_0

A seleção de variáveis pode ser escrita como um problema de otimização penalizada:

$$\hat{\beta}_{\lambda}^{\ell_0} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2 + \lambda \sum_{j=1}^p \mathbb{I}(\beta_j \neq 0) \right\}.$$

A penalização $\sum_{j=1}^p \mathbb{I}(\beta_j \neq 0)$ conta o número de coeficientes não nulos.

Efeito de λ :

- $\lambda = 0$: mínimos quadrados usual (nenhuma variável descartada).
- $\lambda \rightarrow \infty$: todos os coeficientes angulares são zero ($\hat{\psi} = \bar{y}$).

Problema: resolver essa otimização requer avaliar 2^p modelos!

Limitações da seleção de variáveis

- É uma abordagem discreta: cada variável entra ou sai do modelo. Não há meio termo.
- Alta variabilidade: pequenas perturbações nos dados podem levar a subconjuntos bem diferentes.
- Quando p é grande, mesmo forward/backward podem ser instáveis.

Ideia alternativa

Em vez de selecionar variáveis de forma discreta, podemos encolher (*shrink*) os coeficientes em direção a zero de forma contínua.

⇒ Isso nos leva à regularização.

Da penalização ℓ_0 para ℓ_1 e ℓ_2

A penalização ℓ_0 ($\sum \mathbb{I}(\beta_j \neq 0)$) é descontínua: uma pequena mudança em β_j pode alterar drasticamente a penalização. Isso gera instabilidade e intratabilidade computacional.

Alternativa: usar normas contínuas como medida de complexidade.

β	$\sum_{j=1}^p \mathbb{I}(\beta_j \neq 0)$ (norma ℓ_0)	$\sum_{j=1}^p \beta_j $ (norma ℓ_1)	$\sum_{j=1}^p \beta_j^2$ (norma ℓ_2^2)
(0, 0, ..., 0)	0	0	0,0
(0,1, 0,1, ..., 0,1)	10	1	0,1
(1, 1, ..., 1)	10	10	10,0

As linhas 2 e 3 geram previsões muito diferentes, mas têm a mesma norma ℓ_0 . A norma ℓ_1 captura melhor a diferença de complexidade entre esses modelos.

A ideia central da regularização

A regularização oferece um caminho alternativo à seleção de variáveis: manter todas as variáveis, mas penalizar coeficientes grandes.

Objetivo: encontrar $\hat{\beta}$ que minimiza

$$\underbrace{\sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta)^2}_{\text{ajuste aos dados}} + \underbrace{\lambda \cdot \text{Pen}(\beta)}_{\text{penalização}},$$

em que $\lambda \geq 0$ é o parâmetro de regularização.

Dois casos clássicos:

- $\text{Pen}(\beta) = \sum_{j=1}^p \beta_j^2 \Rightarrow$ **Ridge**
- $\text{Pen}(\beta) = \sum_{j=1}^p |\beta_j| \Rightarrow$ **Lasso**

O estimador Ridge é:

$$\hat{\beta}_{\lambda}^{\text{ridge}} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right\}.$$

Solução em forma fechada:

$$\hat{\beta}_{\lambda}^{\text{ridge}} = (\mathbb{X}^{\top} \mathbb{X} + \lambda \mathbf{I}_{p+1})^{-1} \mathbb{X}^{\top} \mathbb{Y},$$

em que $\mathbf{I}_{p+1}$ é a matriz identidade $(p+1) \times (p+1)$.

Atenção: a penalização *não* inclui o intercepto β_0 . Na prática, centralizamos $\mathbb{Y}$ e padronizamos as colunas de $\mathbb{X}$ antes do ajuste.


Por que $\mathbb{X}^\top \mathbb{X} + \lambda \mathbf{I}$ é sempre inversível?

No OLS, precisamos que $\mathbb{X}^\top \mathbb{X}$ seja inversível $\Rightarrow$ requer $n \geq p + 1$ e ausência de colinearidade.

Na Ridge, isso não é necessário. Para qualquer $\lambda > 0$, a matriz $\mathbb{X}^\top \mathbb{X} + \lambda \mathbf{I}_{p+1}$ é inversível, mesmo quando $p > n$ (**Provar**).

$\Rightarrow$ A Ridge pode ser usada mesmo em problemas de alta dimensão, ao contrário do OLS!

Efeito de λ na Ridge




- $\lambda = 0$: recuperamos o estimador de mínimos quadrados usual.
- $\lambda \rightarrow \infty$: os coeficientes são encolhidos em direção a zero, mas nunca o atingem exatamente.

Interpretação via viés-variância

Aumentar λ :

- Aumenta o viés: $\hat{\beta}_{\lambda}^{\text{ridge}}$ se afasta de $\hat{\beta}^{\text{OLS}}$.
- Diminui a variância: os coeficientes são mais estáveis entre amostras.



O λ^* ótimo equilibra viés e variância. Escolhemos λ via validação cruzada.

Por que padronizar as variáveis?

O termo de penalização $\lambda \sum_{j=1}^p \beta_j^2$ depende da escala das variáveis.

Se x_1 está em metros e x_2 em quilômetros, o coeficiente $\hat{\beta}_1$ será naturalmente muito menor que $\hat{\beta}_2$.

Sem padronização, a penalização seria desigual.

Antes de ajustar Ridge (ou Lasso), padronizar cada preditor:

$$\tilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

usando a média e o desvio padrão do conjunto de treinamento.

O estimador Lasso (Least Absolute Shrinkage and Selection Operator):

$$\hat{\beta}_{\lambda}^{\text{lasso}} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right\}.$$

Diferença fundamental em relação à Ridge:

- A penalização ℓ_1 (valor absoluto) faz com que alguns coeficientes sejam exatamente zero.
- O Lasso realiza seleção de variáveis automática e encolhimento simultaneamente.
- Não há solução em forma fechada; usam-se algoritmos de otimização (ex: coordenada descendente).


- Conforme λ cresce, mais coeficientes se tornam exatamente zero.
- O Lasso produz modelos esparsos: com poucas variáveis ativas.
- λ é escolhido via validação cruzada.

Ambos os problemas podem ser escritos como:

$$\min_{\boldsymbol{\beta}} \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \boldsymbol{\beta})^2 \quad \text{sujeito a} \quad \begin{cases} \sum_{j=1}^p \beta_j^2 \leq t & \text{(Ridge)} \\ \sum_{j=1}^p |\beta_j| \leq t & \text{(Lasso)} \end{cases}$$

Ridge vs. Lasso: interpretação geométrica

O losango do Lasso tem vértices nos eixos: as curvas de nível do EQM tendem a tocar nesses vértices, produzindo coeficientes exatamente zero.



Exemplo: tempo de execução e desempenho

Simulação (Izbicki & Santos, 2020, Exemplo 3.1):

$n = 500$, $p = 20$ covariáveis, mas apenas $x_1, \dots, x_5$ são relevantes.

Método	Variáveis selecionadas	Tempo	Risco est.
Mín. Quadrados	Todas	0,002 s	14,63
Melhor AIC (best subset)	$x_1-x_5, x_{10}, x_{12}, x_{13}, x_{19}, x_{20}$	1h 20min	0,30
Forward Stepwise	$x_1-x_5, x_{10}, x_{12}, x_{13}, x_{19}, x_{20}$	0,46 s	0,30
Ridge	Todas (encolhidas)	0,16 s	0,33
Lasso	x_1-x_5 (corretas!)	0,08 s	0,25

Conclusões:

- Best subset e forward encontram as mesmas variáveis, mas o tempo difere drasticamente.
- Lasso: menor risco, mais rápido e selecionou exatamente as variáveis corretas.
- Ridge melhora muito sobre OLS, mas não faz seleção.

Equivalência via Lagrangiano

A formulação penalizada e a formulação restrita são equivalentes. Considere o Lasso restrito:

$$\min_{\beta} \|\mathbb{Y} - \mathbb{X}\beta\|^2 \quad \text{sujeito a} \quad \|\beta\|_1 \leq s.$$

O Lagrangiano com multiplicador $\lambda \geq 0$ é:

$$\mathcal{L}(\beta, \lambda) = \|\mathbb{Y} - \mathbb{X}\beta\|^2 + \lambda (\|\beta\|_1 - s).$$

Como s é constante, minimizar $\mathcal{L}$ em β equivale a minimizar:

$$\|\mathbb{Y} - \mathbb{X}\beta\|^2 + \lambda \|\beta\|_1,$$

que é exatamente a formulação penalizada do Lasso.

Analogamente, para a Ridge: $\|\beta\|_2^2 \leq s \Leftrightarrow$ penalização $\lambda \|\beta\|_2^2$.

Correspondência: para cada $\lambda > 0$, existe $s > 0$ (e vice-versa) tal que as soluções coincidem. A relação $\lambda \leftrightarrow s$ é monótona decrescente: mais penalização (λ maior) equivale a uma restrição mais apertada (s menor).

Ridge vs. Lasso: quando usar cada um?

Ridge

Melhor quando *muitos*
preditores contribuem
(coeficientes pequenos,
mas nenhum é zero)
Não faz seleção

Lasso

Melhor quando *poucos*
preditores são relevantes
(modelo esparsos)
Faz seleção automática

Na prática, não sabemos qual cenário é o real. A solução é:

- Ajustar ambos e comparar via validação cruzada.
- Ou usar o Elastic Net, que combina ambas as penalizações:

$$\lambda \left[\alpha \sum_{j=1}^p |\beta_j| + (1 - \alpha) \sum_{j=1}^p \beta_j^2 \right], \quad \alpha \in [0, 1].$$

Receita prática:

1. Definir uma grade de valores para λ : $\lambda_1 > \lambda_2 > \dots > \lambda_L$.
2. Para cada λ_ℓ , calcular o EQM de validação cruzada (k -fold):

$$\text{CV}(\lambda_\ell) = \frac{1}{k} \sum_{j=1}^k \frac{1}{|V_j|} \sum_{i \in V_j} \left(y_i - \hat{\psi}_{\lambda_\ell}^{(-j)}(\mathbf{x}_i) \right)^2,$$

em que $\hat{\psi}_{\lambda_\ell}^{(-j)}$ é o modelo ajustado sem o fold j .

3. Selecionar $\lambda^* = \arg \min_{\lambda_\ell} \text{CV}(\lambda_\ell)$.

Implementação em R

Pacote glmnet:

```
library(glmnet)

# Preparar matriz de preditores (sem intercepto)
X <- model.matrix(y ~ ., data = treino)[, -1]
y <- treino$y

# Ridge (alpha = 0)
ridge_cv <- cv.glmnet(X, y, alpha = 0)
plot(ridge_cv)


# Lasso (alpha = 1)
lasso_cv <- cv.glmnet(X, y, alpha = 1)
plot(lasso_cv)

# Predição com lambda.min ou lambda.1se
pred <- predict(lasso_cv, s = "lambda.1se", newx = X_teste)
```

O glmnet padroniza internamente as variáveis e escolhe a grade de λ automaticamente.

Mensagem

Seleção de variáveis e regularização são estratégias diferentes para o mesmo objetivo: trocar viés por variância de modo a reduzir o risco de predição.



Interpretação bayesiana da regularização

Sob o enfoque bayesiano, atribuímos uma distribuição a priori aos coeficientes β . O estimador pontual é obtido pela moda a posteriori (MAP):

$$\hat{\beta}^{\text{MAP}} = \arg \max_{\beta} p(\beta \mid \text{dados}) = \arg \max_{\beta} \{ \log L(\beta) + \log \pi(\beta) \},$$

em que $L(\beta)$ é a verossimilhança e $\pi(\beta)$ é a priori.

Sob erros gaussianos, $\log L(\beta) \propto -\sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta)^2$. Logo:

$$\hat{\beta}^{\text{MAP}} = \arg \min_{\beta} \left\{ \sum_{i=1}^n (y_i - \mathbf{x}_i^\top \beta)^2 - 2 \log \pi(\beta) \right\}.$$

A penalização $-2 \log \pi(\beta)$ depende da escolha da priori!

Priori gaussiana $\Leftrightarrow$ Ridge, priori Laplace $\Leftrightarrow$ Lasso

Ridge

Priori: $\beta_j \stackrel{\text{iid}}{\sim} \text{Normal}(0, \tau^2)$

$$-2 \log \pi(\beta) \propto \frac{1}{\tau^2} \sum_{j=1}^p \beta_j^2$$

$$\lambda = 1/\tau^2$$

Lasso

Priori: $\beta_j \stackrel{\text{iid}}{\sim} \text{Laplace}(0, b)$

$$-2 \log \pi(\beta) \propto \frac{1}{b} \sum_{j=1}^p |\beta_j|$$

$$\lambda = 1/b$$

A priori gaussiana concentra massa ao redor de zero de forma suave: coeficientes pequenos, mas nenhum exatamente zero. A priori Laplace tem um pico em zero: favorece esparsidade.

Resumindo: regularizar é equivalente a incorporar informação a priori de que os coeficientes são pequenos. O parâmetro λ reflete o grau de confiança nessa informação.

Recapitulando

- Seleção de variáveis busca o melhor subconjunto de preditores. Best subset é ótimo mas caro; forward/backward são alternativas gulosas eficientes.
- Ridge (ℓ_2) encolhe todos os coeficientes em direção a zero, sem zerar nenhum. Útil quando muitos preditores contribuem.
- Lasso (ℓ_1) encolhe e zera coeficientes, realizando seleção automática. Útil quando o modelo subjacente é esparso.
- O parâmetro de regularização λ controla a intensidade da regularização e é escolhido via validação cruzada.
- Tudo se conecta ao trade-off viés-variância: a regularização introduz viés para reduzir variância e, assim, melhorar a predição.