

Instruções para o trabalho final

O trabalho final da disciplina consistirá no desenvolvimento de um projeto e na apresentação de um seminário. O grupo, com no mínimo 3 e no máximo 5 alunos, deverá optar por uma das duas modalidades descritas abaixo. A avaliação será dividida entre um Relatório Técnico (peso 50%) e a Apresentação Oral (peso 50%).

1 Modalidades e entregáveis

1.1. Modalidade A: Projeto aplicado de mineração de dados

O foco desta modalidade é a resolução de um problema real de ponta a ponta:

- **Relatório (máx. 8 páginas):** Deve detalhar a análise exploratória, justificar as decisões de pré-processamento (ex: tratamento de dados faltantes), os modelos escolhidos (mínimo de dois para comparação) e discutir o desempenho usando métricas adequadas.
- **Código:** *Script* (R ou Python) ou *Notebook* contendo a implementação completa e reproduzível: desde a importação e limpeza dos dados brutos até a geração dos gráficos e cálculo das métricas finais.

1.2. Modalidade B: Reprodução de artigo científico

O foco desta modalidade é o estudo metodológico e a prova de conceito de um método recente ou clássico da literatura estatística e de aprendizado de máquina.

- **Relatório (máx. 8 páginas):** Deve conter a tradução didática da teoria proposta pelos autores originais, a metodologia adotada pelo grupo para replicar o experimento e uma análise crítica (o método foi fácil de implementar? Os resultados obtidos refletem o prometido no artigo?).
- **Código:** Implementação do algoritmo estudado (ou adaptação do código fornecido pelos autores) devidamente aplicado a uma base de dados real (como dados de risco de crédito, fraude, textos) para atestar que a técnica funciona na prática. Trabalhos exclusivamente teóricos não serão aceitos.

2 Diretrizes para as entregas

2.1. Temas sorteados

Cada grupo será alocado em um dos temas abaixo. O projeto e a base de dados escolhida devem respeitar o seguinte escopo:

1. **Regressão:** O projeto deve focar na modelagem e predição de uma variável quantitativa. O grupo deverá comparar ao menos dois modelos ou algoritmos e justificar as

escolhas com base em critérios objetivos. A análise deve interpretar as métricas de erro (ex: RMSE, MAE) no contexto do problema e discutir quais variáveis mais contribuem para a predição.

2. **Classificação:** O projeto deve focar em prever categorias (binárias ou multiclasse). O grupo deverá enfrentar ao menos um desafio metodológico relevante, como desbalanceamento de classes, escolha de limiar de decisão ou seleção de métricas adequadas (ex: F1-Score, ROC-AUC), justificando as escolhas feitas. A análise deve discutir o que os erros do modelo significam no problema: as consequências de um falso positivo e de um falso negativo são igualmente custosas?
3. **Agrupamento:** O projeto deve aplicar aprendizado não supervisionado para encontrar estruturas ocultas nos dados. O grupo deverá testar ao menos um algoritmo (ex: K-means, agrupamento hierárquico) e justificar a escolha do número de grupos por critérios objetivos. A entrega deve incluir interpretação dos perfis encontrados e discussão sobre a utilidade prática da segmentação obtida.
4. **Mineração de Textos:** O projeto deve extrair informação útil de dados textuais. O grupo deverá aplicar etapas de pré-processamento (tokenização, remoção de stopwords, stemming) e ao menos uma técnica de modelagem, como classificação de sentimento, agrupamento de documentos ou extração de tópicos (LDA). A interpretação deve ir além das métricas numéricas, discutindo o que os padrões encontrados significam no contexto dos dados.
5. **Interpretabilidade de Modelos:** O projeto deve focar em compreender o comportamento de um modelo preditivo, indo além da avaliação de desempenho. O grupo deverá aplicar ao menos duas técnicas de interpretabilidade, como importância de variáveis, gráficos de efeito parcial (PDP), valores SHAP ou inspeção de coeficientes regularizados, respondendo *por que* o modelo prediz o que prediz. A análise deve discutir se as relações encontradas fazem sentido no contexto do problema.
6. **Deteção de Anomalias:** O projeto deve focar em identificar comportamentos atípicos e raros (ex: fraudes, falhas operacionais). O grupo deverá aplicar ao menos uma abordagem de detecção, supervisionada caso haja rótulos disponíveis, ou não supervisionada (ex: Isolation Forest) caso contrário, e discutir como avaliou a qualidade das detecções.

2.2. Proposta inicial

Após a formação dos grupos, será realizado um sorteio definindo o macro-tema (ex: Classificação, Regressão, Agrupamento, etc.) para cada equipe. Antes de iniciar o desenvolvimento, o grupo deve submeter uma proposta (em PDF de no máximo 1 página) para aprovação, que obrigatoriamente deve estar alinhada ao tema sorteado. A proposta deve detalhar:

- **Para a Modalidade A (Projeto):** O problema a ser resolvido, a justificativa de adequação ao tema sorteado e o link para a base de dados escolhida (se houver).
- **Para a Modalidade B (Artigo):** O título e o link/PDF do artigo científico escolhido (que deve aplicar ou propor metodologias dentro do tema sorteado), um parágrafo resumindo o método e a indicação de qual base de dados será utilizada.

Dentro da restrição da tarefa sorteada, os grupos possuem liberdade para escolher a área de aplicação (finanças, saúde, esportes, etc.) e a base de dados de sua preferência.

2.3. Relatório

Independentemente da modalidade, o relatório deve ser entregue em PDF, com limite de **8 páginas**, estruturado de forma técnica contendo:

1. Introdução: Contextualização do problema ou do artigo e objetivos do grupo.
2. Metodologia: Descrição rigorosa das técnicas, bases de dados e algoritmos.
3. Resultados e Discussão: Tabelas, gráficos de saída e interpretação dos achados.
4. Conclusão: Síntese do trabalho e possíveis trabalhos futuros.

2.4. Seminário (Apresentação Oral)

- Tempo de Apresentação: até 20 minutos por grupo.
- Arguição e dúvidas: Ao final da apresentação, haverá 5 minutos de arguição. As perguntas poderão ser direcionadas pelo professor a qualquer membro da equipe, visando garantir que todos participaram ativamente.

2.5. Originalidade

O projeto apresentado deve ser original e desenvolvido exclusivamente para a disciplina de Mineração de Dados. Não será permitido o reaproveitamento de trabalhos desenvolvidos para outras disciplinas, projetos de pesquisa (como Iniciação Científica), Trabalhos de Conclusão de Curso (TCC) ou atividades profissionais. Caso o grupo deseje utilizar uma base de dados com a qual algum membro já tenha trabalhado, a abordagem metodológica, os modelos aplicados e os objetivos da análise devem ser diferentes, exigindo aprovação prévia explícita na fase de submissão da Proposta Inicial.

2.6. Uso de Ferramentas de Inteligência Artificial (IA)

O uso de assistentes generativos de IA (como ChatGPT, Gemini, etc.) é permitido como ferramenta de apoio ao aprendizado (ex: depuração de código, revisão textual ou *brainstorming*). No entanto, aplicam-se as seguintes regras:

- Transparência: Caso o grupo utilize IA de forma substancial na elaboração do código ou do texto, deve incluir uma breve declaração na seção de Metodologia do relatório, explicando como e para qual finalidade a ferramenta foi utilizada.
- Responsabilidade: Os alunos são integralmente responsáveis por qualquer erro técnico, metodológico ou conceitual gerado pela IA. A inclusão de referências bibliográficas inventadas (*alucinações*) ou a entrega de códigos que os membros do grupo não saibam explicar durante a arguição resultarão em penalização na nota final.

2.7. Instruções de Envio por E-mail

Todas as comunicações e entregas devem ser enviadas exclusivamente para o e-mail **helton@ufscar.br**, seguindo as regras abaixo:

- **Formação dos grupos:** Enviar um e-mail com o assunto [Mineração de Dados] - Formação de Grupo. No corpo do e-mail, listar o nome completo e o RA de todos os integrantes.
- **Entregas (propostas e relatórios):** Utilize o padrão [Mineração de Dados] - Entregável - Número do grupo. Exemplo: [Mineração de Dados] - Proposta - Grupo 1.

- **Formato dos anexos:** A proposta e o relatório final devem ser enviados em formato **.pdf**. O código-fonte e eventuais bases de dados devem ser compactados em um único arquivo **.zip** ou **.rar**.

3 Critérios de Avaliação

1. Qualidade do relatório (50%): Rigor técnico e metodológico, clareza na escrita, correta formatação e interpretação adequada dos resultados estatísticos.
2. Seminário (50%): Organização da apresentação, gestão do tempo, organização e reprodutibilidade do código entregue e domínio técnico demonstrado na arguição.

4 Cronograma

As datas abaixo referem-se aos prazos para cada etapa do trabalho final:

Etapas	Data Limite
Formação dos grupos (Nomes e RAs)	14/04
Sorteio dos temas para os grupos	16/04
Envio da proposta	30/04
Devolutiva e aprovação do professor	08/05
Entrega do relatório e código	25/06
Início dos seminários	02/07