

Universidade Federal de São Carlos (UFSCar)

Departamento de Estatística

MINERAÇÃO DE DADOS

Proposta de Projeto

Projeto Mineração – Grupo 5

Integrantes:

Nome	RA
Arthur Pereira Gon	811464
Giovanni Roberti	811676
Igor Figueiredo	791420
Lucas Yukio	813650
Murilo Cassiavilani	812067

Tema e Modalidade

Tema sorteado: 5 – Interpretabilidade de Modelos. **Modalidade:** A – Projeto aplicado de mineração de dados.

Visão Geral

O projeto propõe um estudo abrangente de interpretabilidade aplicado aos principais paradigmas de modelagem da disciplina. O grupo desenvolverá aplicações em cada área sorteada aos demais grupos (regressão, classificação, agrupamento, mineração de textos e detecção de anomalias), utilizando métodos específicos de interpretação para comparar resultados e explicar por que os modelos predizem o que predizem.

Estrutura por Paradigma

Para cada paradigma, serão ajustados modelos representativos e aplicadas técnicas de interpretabilidade adequadas:

1. **Regressão:** Modelos lineares regularizados (Ridge, Lasso) e árvores (Random Forest, XGBoost). Interpretação via coeficientes, PDP e SHAP para quantificar contribuições das preditoras nas predições quantitativas.
2. **Classificação:** Regressão Logística com Lasso, Random Forest e XGBoost. Uso de coeficientes regularizados, importância por permutação, PDP e SHAP para decompor predições e interpretar efeitos sobre probabilidades de classe.
3. **Agrupamento:** K-Means e agrupamento hierárquico. Interpretação dos perfis pela análise das variáveis que mais caracterizam cada grupo, permitindo segmentação acionável.
4. **Mineração de Textos:** Modelagem de tópicos (LDA) e classificação de documentos. Interpretação por inspeção das palavras mais relevantes por tópico e análise de contribuições de termos nas predições.
5. **Detecção de Anomalias:** Isolation Forest e LOF. Interpretação das anomalias via identificação das variáveis que mais se desviam do perfil médio, com explicações locais.

Base de Dados

As bases serão selecionadas de repositórios públicos (UCI, Kaggle) de forma a cobrir cada paradigma. A escolha definitiva será submetida à aprovação do professor, garantindo variáveis interpretáveis em cada domínio.

Implementação

Desenvolvimento em R com `tidymodels` (modelagem), `DALEX` e `fastshap` (interpretabilidade), `tidytext` (textos) e `dbscan/isolationForest` (anomalias). Código entregue como *notebook* reproduzível.