

Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Estatística



Relatório do Projeto de Interpretabilidade de Modelos

Grupo 5

Arthur Pereira Gon
Giovanni Roberti
Igor Figueiredo Pereira da Silva
Lucas Yukio Iyda
Murilo Cassiavilani

RA: 811464
RA: 811676
RA: 791420
RA: 813650
RA: 812067

Docente Helton Graziadei de Carvalho

1. Introdução

Com o avanço do uso de modelos preditivos em diferentes áreas, tornou-se cada vez mais importante não apenas obter boas previsões, mas também compreender os fatores que levam o modelo a produzir determinado resultado. Em muitos problemas aplicados, avaliar apenas métricas de desempenho não é suficiente, pois modelos com resultados semelhantes podem utilizar as variáveis de formas diferentes. Dessa forma, a interpretabilidade passa a ter papel central na análise, permitindo investigar quais variáveis são mais relevantes, qual a direção de seus efeitos e se as relações identificadas fazem sentido no contexto do problema.

Nesse contexto, o presente projeto tem como objetivo investigar a interpretabilidade de modelos de regressão aplicados à predição de salários de jogadores da NBA. A análise busca compreender quais características individuais, estatísticas de desempenho e informações associadas ao contexto esportivo estão mais relacionadas ao salário anual dos jogadores na temporada 2022–2023.

Para isso, foram ajustados diferentes modelos de regressão, incluindo Regressão Linear Clássica, Regressão Ridge, Regressão Lasso, Random Forest e HistGradientBoosting. Essa escolha permite comparar modelos lineares e regularizados, cuja interpretação pode ser feita diretamente por meio dos coeficientes, com modelos baseados em árvores, que possuem maior flexibilidade para capturar relações não lineares e interações entre variáveis. Além da avaliação do desempenho preditivo, o trabalho aplica técnicas de interpretabilidade com o objetivo de responder a questões como: quais variáveis mais influenciam a predição dos salários? As relações identificadas fazem sentido no contexto da NBA? Os diferentes modelos apontam para conclusões semelhantes ou divergentes?

2. Metodologia

a) Base de dados e definição do problema

A base de dados utilizada contém informações de 467 jogadores da NBA referentes à temporada 2022–2023. Cada linha representa um jogador, descrito por características individuais, estatísticas de desempenho e informações da equipe. O objetivo é prever o salário anual com base em estatísticas individuais, como pontos, assistências, rebotes e minutos em quadra, além de métricas avançadas de impacto esportivo.

Para manter correspondência com as colunas originais do dataset, as principais siglas são usadas ao longo do relatório: MP indica minutos por jogo; PTS, pontos; GP, jogos disputados; USG%, taxa de uso ofensivo; PER, Player Efficiency Rating; BPM, Box Plus/Minus; VORP, valor sobre jogador de reposição; WS, Win Shares; AST, assistências; TOV, perdas de bola; STL, roubos; BLK, tocos; e PG, Point Guard.

b) Análise exploratória dos dados

A variável Salary, que representa o salário anual, apresenta média de US\$ 8,4 milhões e mediana de US\$ 3,7 milhões, indicando distribuição fortemente assimétrica à direita: poucos jogadores concentram contratos milionários. A idade média é 25,8 anos, com concentração entre 23 e 29 anos. As métricas de desempenho exibem elevada variabilidade, refletindo diferenças entre reservas, titulares e atletas de elite.

A Figura ?? resume os principais achados. A distribuição salarial confirma a assimetria positiva; o painel de correlações com salário mostra associação forte com PTS ($r = 0,73$), VORP ($r = 0,68$) e MP ($r = 0,64$). Também há multicolinearidade entre PER e BPM, com $r = 0,90$. Análises complementares indicam pico remuneratório entre 26 e 34 anos e maior salário médio entre jogadores PG.

Análise exploratória dos salários da NBA




Figura 1: Análise exploratória dos salários: distribuição assimétrica, correlação com métricas de desempenho, efeito da idade e diferenças médias por posição.

c) Pré-processamento

Foram removidos 38 jogadores com salário inferior a US\$ 500.000 (contratos *Two-Way*, de 10 dias ou proporcionais), reduzindo a base de 467 para 429 observações. Valores ausentes em percentuais de arremesso foram imputados pela mediana por posição, preservando diferenças estruturais entre armadores, alas e pivôs.

Aplicou-se transformação logarítmica em Salary, reduzindo a assimetria de 1,75 para aproximadamente 0,06 e melhorando a adequação dos modelos paramétricos. Criaram-se variáveis derivadas por jogo e por minuto, como Age_sq, AST_to_TOV, STL_BLK_sum e Toxic_Contract, além das categorias Rookie, Prime e Veteran. A centralização da idade reduziu o VIF de Age de 512 para 9,2. Variáveis redundantes, como TS%, PER, WS, eFG%, 3PAr e FTr, foram removidas; o VIF máximo final foi 13,8 para PTS_per_GP. O conjunto foi dividido em treino e teste (75/25), estratificado por posição ($n_{\text{teste}} = 108$).

Tabela 1: VIF após o pré-processamento

Variável	VIF	Status
PTS_per_GP	13,8	Marginalmente alto
MP	11,1	Marginalmente alto
STL_BLK_sum	9,8	Aceitável
Age	9,2	Aceitável
AST_per_min	8,3	Aceitável
BPM	6,1	Aceitável

d) Modelos ajustados e métricas

Foram ajustados cinco modelos: OLS, Ridge (L_2), Lasso (L_1), Random Forest e HistGradientBoosting (HGB). Os modelos lineares permitem interpretação direta dos coeficientes; Ridge estabiliza estimativas sob multicolinearidade; Lasso realiza seleção de variáveis; Random Forest e HGB capturam não linearidades e interações. O desempenho foi avaliado por R^2 , RMSE, MAE, MSLE e MAPE, na validação cruzada e no conjunto de teste (*holdout*).

e) Técnicas de interpretabilidade

Nos modelos lineares, analisaram-se os coeficientes de OLS, Ridge e Lasso. No HGB, aplicaram-se importância por permutação (queda no R^2 ao embaralhar cada variável), valores SHAP (SHapley Additive exPlanations, contribuição marginal por observação) e Partial Dependence Plots (PDP), gráficos de dependência parcial que isolam o efeito médio de uma variável sobre a predição. O HGB foi escolhido como modelo principal para interpretação avançada por combinar menor MAPE (52,18%) com capacidade de modelar relações não lineares, como o efeito parabólico da idade.

f) Uso de ferramentas de Inteligência Artificial

Ferramentas de Inteligência Artificial generativa foram utilizadas como apoio na revisão textual, melhoria da clareza da escrita acadêmica e organização de trechos de código. As decisões metodológicas, a escolha dos modelos, a análise dos resultados e as interpretações finais foram realizadas pelo grupo.

3. Resultados e Discussão

Foram avaliados cinco algoritmos de regressão. A Tabela ?? apresenta o desempenho no conjunto de teste.

Tabela 2: Desempenho dos modelos no conjunto de teste

Modelo	R^2 Teste	RMSE (log)	MAE (log)	MSLE	MAE (USD)	MAPE
OLS	0,5621	0,7569	0,5703	0,573	3.850.058	58,91%
Ridge	0,5878	0,7344	0,5474	0,539	3.721.480	55,34%
Lasso	0,5810	0,7405	0,5545	0,548	3.778.538	56,49%
Random Forest	0,5503	0,7671	0,5470	0,588	3.580.678	52,85%
HistGradientBoosting	0,5585	0,7600	0,5518	0,578	3.678.298	52,18%

O Ridge obteve o maior R^2 (0,5878), explicando cerca de 59% da variabilidade salarial. O HGB e o Random Forest apresentaram os menores MAPE (52,18% e 52,85%). Todos os modelos ficaram na faixa $R^2 \in [0,55, 0,59]$. Na validação cruzada, os modelos lineares foram mais estáveis (Tabela ??); o HGB equilibrou variância moderada com menor erro percentual.

Tabela 3: Estabilidade na validação cruzada (R^2 CV std)

Modelo	Std	Interpretação
OLS	0,052	Muito estável
Ridge	0,063	Estável
Lasso	0,058	Estável
Random Forest	0,113	Alta variância
HistGradientBoosting	0,097	Variância moderada

a) Interpretação dos modelos lineares

Os coeficientes OLS representam efeitos marginais (*ceteris paribus*). A Tabela ?? destaca os principais preditores: MP (+0,74), Age (+0,57), categoria Rookie (+0,55) e USG% (+0,21); Age_sq (−0,16) confirma declínio pós-pico de carreira. Alguns coeficientes apresentam sinal aparentemente contraditório (PTS_per_GP −0,11; Position_PG −0,12), reflexo de colinearidade residual entre métricas de desempenho. Por isso, devem ser interpretados com cautela, não como relações causais.

Tabela 4: Principais coeficientes do modelo OLS

Variável	Coeficiente	Interpretação
MP	+0,74	Principal preditor salarial
Age	+0,57	Idade aumenta salário até o pico
Experience_Category_Rookie	+0,55	Efeito contratual rookie scale
USG%	+0,21	Participação ofensiva valorizada
Age_sq	−0,16	Declínio pós-pico de carreira
AST_per_min	+0,10	Eficiência de passe
BPM	+0,10	Impacto geral no jogo

A comparação Ridge versus Lasso (Tabela ??) confirma robustez: MP (+0,56 / +0,69), Age (+0,41 / +0,48) e USG% (+0,18 / +0,20) mantêm sinais consistentes. O Lasso foi mais agressivo na seleção, zerando variáveis menos relevantes.

Tabela 5: Comparação entre coeficientes Ridge e Lasso


Variável	Ridge	Lasso
MP	+0,56	+0,69
Age	+0,41	+0,48
Age_sq	−0,06	−0,09
USG%	+0,18	+0,20
Rookie	+0,21	+0,33
Veteran	+0,25	+0,21

b) Interpretação do HistGradientBoosting

A interpretação do HistGradientBoosting foi organizada do comportamento global para a explicação local. Primeiro, avaliou-se quais variáveis sustentam o desempenho do modelo; depois, analisou-se a direção dos efeitos por SHAP; por fim, foi escolhido um jogador específico para mostrar como a predição é formada.

A importância por permutação confirma a dominância de MP (0,452) e Age (0,262). Embaralhar MP reduz o R^2 em cerca de 0,45 pontos no teste (aproximadamente 81% do desempenho do modelo); juntas, MP e Age somam importância acumulada de 0,71, evidenciando que tempo em quadra e estágio da carreira concentram grande parte da informação salarial. PTS_per_GP (0,041) e USG% (0,023) aparecem em um segundo nível, indicando que produtividade ofensiva importa, mas principalmente depois de controlar utilização e estágio da carreira.

O PDP mostra que o salário previsto cresce até aproximadamente 28–30 anos e depois declina gradualmente. O resumo SHAP acrescenta a direção dos efeitos: valores altos de MP deslocam a predição para cima, enquanto idades fora do pico tendem a reduzir o salário previsto. Para melhorar a leitura, as figuras SHAP mantêm apenas as variáveis de maior impacto e agregam o restante em “Outras variáveis”.



Efeitos parciais (PDP) do HGB




Figura 2: Interpretação global do HistGradientBoosting: importância por permutação e efeitos parciais das quatro variáveis mais relevantes.




Figura 3: Resumo SHAP do HistGradientBoosting com as principais variáveis. Cada ponto representa um jogador; a posição horizontal indica quanto a variável aumentou ou reduziu a predição.




Figura 4: Importância global SHAP com “Outras variáveis” acumulado.

Para a leitura local, escolheu-se Stephen Curry por ser um caso bem previsto: US\$ 46,3 milhões estimados contra US\$ 48,1 milhões observados.




Figura 5: Contribuições SHAP locais para Stephen Curry, em milhões de dólares. O grupo “Outras” reúne contribuições menores que, individualmente, teriam baixa legibilidade.

c) Limitações e maiores erros

A leitura local de Curry mostra um caso em que o modelo acerta bem um jogador de elite. Em contraste, a Tabela ?? apresenta os maiores erros no teste. Kemba Walker (erro de US\$ 32,5 milhões, 87%) exemplifica contratos tóxicos: salário elevado por acordo anterior, com baixa participação recente. Casos como Russell Westbrook e Jonathan Isaac envolvem supermax antigo e lesões graves, fatores ausentes na base. O modelo captura bem a remuneração baseada em desempenho, mas não incorpora dinâmica contratual e mercadológica da NBA.

Tabela 6: Maiores erros de previsão no conjunto de teste

Jogador	Real	Predito	Erro (USD)	Principal causa
Kemba Walker	37,3M	4,8M	32,5M	Contrato tóxico
Myles Turner	35,1M	9,4M	25,7M	Extensão contratual
Russell Westbrook	47,1M	28,9M	18,2M	Supermax antigo
Shai Gilgeous-Alexander	30,9M	13,0M	17,9M	Extensão jovem
Jonathan Isaac	17,4M	0,7M	16,7M	Lesões graves

4. Conclusão

O projeto mostrou que estatísticas de quadra explicam parcela relevante dos salários da NBA, mas não capturam integralmente fatores contratuais e mercadológicos. Os modelos tiveram desempenho semelhante ($R^2 \approx 0,55-0,59$), com maior R^2 no Ridge e menor MAPE no HGB. As técnicas de interpretabilidade convergiram para a mesma leitura: minutos jogados e idade são os principais determinantes salariais, seguidos por produtividade ofensiva. Casos extremos, como contratos antigos e jogadores lesionados, evidenciam as limitações da base, enquanto coeficientes, permutation importance, PDP e SHAP tornam as previsões mais transparentes.