

Fundamentos de aprendizagem supervisionada

Mineração de Dados

Helton Graziadei

Universidade Federal de São Carlos — UFSCar

O que é aprendizagem supervisionada?

Dado um fenômeno de interesse, observamos um vetor de $p \geq 1$ preditoras

$$X = (X_1, \dots, X_p) \in \mathbb{R}^p$$

e uma variável resposta Y .

De forma geral, o propósito da aprendizagem supervisionada é compreender como X e Y se relacionam.

Regressão

A resposta é quantitativa:

$$Y \in \mathbb{R}.$$

Exemplos: preço, temperatura, vendas.

Classificação

A resposta é qualitativa e assume um número finito de categorias:

$$Y \in \{0, 1, \dots, c\}.$$

Exemplos: spam/não-spam, diagnóstico.

Embora a distinção pareça simples, cada caso possui resultados teóricos específicos.

As preditoras recebem diferentes nomes dependendo da área:

Preditoras (X)	Resposta (Y)
entradas	saída
variáveis independentes	variável dependente
variáveis explicativas	variável explicada
características (<i>features</i>)	alvo (<i>target</i>)

Regressão

Suponha que o par (X, Y) tenha distribuição conjunta $F_{X,Y}$, que não conhecemos (estamos fazendo inferência).

Problema

Queremos uma função $\psi : \mathbb{R}^p \rightarrow \mathbb{R}$ que minimize o erro de predição esperado:

$$E[(Y - \psi(X))^2] .$$

Observações:

1. Este erro também é chamado *erro de teste esperado* ou risco.
2. Estamos usando uma função de perda quadrática, escolha ligada à Teoria da Decisão.

O erro de predição esperado pode ser reescrito via propriedades da esperança condicional:

$$E[(Y - \psi(X))^2] = E[E[(Y - \psi(X))^2 | X]] = \int E[(Y - \psi(x))^2 | X = x] dF_X(x).$$

Como a integral externa percorre a distribuição de X e o integrando é não-negativo, basta encontrar ψ que minimize o integrando para cada x :

$$\min_{\psi} E[(Y - \psi(x))^2 | X = x].$$

Transformamos assim um problema global em um problema pontual.

Defina $t = \psi(x)$ e considere:

$$g(t) := E[(Y - t)^2 \mid X = x] = E[Y^2 \mid X = x] - 2t E[Y \mid X = x] + t^2.$$

Função de regressão

Defina $t = \psi(x)$ e considere:

$$g(t) := E[(Y - t)^2 \mid X = x] = E[Y^2 \mid X = x] - 2t E[Y \mid X = x] + t^2.$$

Zerando a derivada em t :

$$g'(t) = -2 E[Y \mid X = x] + 2t = 0 \implies t^* = E[Y \mid X = x].$$

Função de regressão

Defina $t = \psi(x)$ e considere:

$$g(t) := E[(Y - t)^2 \mid X = x] = E[Y^2 \mid X = x] - 2t E[Y \mid X = x] + t^2.$$

Zerando a derivada em t :

$$g'(t) = -2 E[Y \mid X = x] + 2t = 0 \implies t^* = E[Y \mid X = x].$$

Como $g''(t) = 2 > 0$, temos de fato um mínimo global.

Resultado A função que minimiza o erro de predição esperado é a função de regressão:

$$\psi(x) = E[Y \mid X = x].$$

Estimando ψ a partir dos dados

Essa solução é formal: não conhecemos $F_{X,Y}$, tampouco conhecemos $E[Y \mid X = x]$.

Suponha que dispomos de dados de treinamento:

$$(X_1, Y_1), \dots, (X_n, Y_n) \quad \text{i.i.d. com distribuição } F_{X,Y}.$$

A ideia central é usar esses dados para construir uma estimativa $\hat{\psi} : \mathbb{R}^p \rightarrow \mathbb{R}$.

Predição vs. Inferência

Há dois propósitos, em geral antagônicos, ao aprender sobre ψ :

Predição

Tratamos $\hat{\psi}$ como uma caixa-preta.

Queremos $E[(Y - \hat{\psi}(X))^2]$ pequeno.

Não importa como $\hat{\psi}$ funciona.

Inferência

Buscamos interpretabilidade.

Entender a relação entre Y e cada X_j .

A forma funcional de $\hat{\psi}$ precisa ser compreensível.

Modelo aditivo

Considere o modelo:

$$Y = \psi(X) + \epsilon,$$

em que:

- X tem distribuição F_X .
- O erro aleatório ϵ é independente de X , com $E[\epsilon] = 0$ e $\text{Var}[\epsilon] = \sigma^2$ (desconhecida).

Consequência: $E[Y \mid X = x] = \psi(x)$.

Interpretação:

- ψ captura a informação sistemática de X sobre Y .
- ϵ representa a incerteza devida a fatores não observados.

Com dados de treinamento $(X_1, Y_1), \dots, (X_n, Y_n)$, o modelo assume:

Modelo

- $Y = \psi(X) + \epsilon$ (par a ser predito).
- $Y_i = \psi(X_i) + \epsilon_i, \quad i = 1, \dots, n.$
- $E[\epsilon] = E[\epsilon_i] = 0.$
- $\text{Var}[\epsilon] = \text{Var}[\epsilon_i] = \sigma^2.$

Independência

- X e os X_i 's seguem F_X .
- ϵ e os ϵ_i 's são mutuamente independentes.
- ϵ é independente dos dados de treinamento.

A predição da resposta Y será $\hat{Y} = \hat{\psi}(X).$

Decomposição: erro redutível e irreduzível

O modelo aditivo permite decompor o erro de predição esperado em componentes interpretáveis.

Resultado

$$E[(Y - \hat{\psi}(x))^2 \mid X = x] = \underbrace{EQM[\hat{\psi}(x)]}_{\text{redutível}} + \underbrace{\sigma^2}_{\text{irreduzível}},$$

em que $EQM[\hat{\psi}(x)] = E[(\hat{\psi}(x) - \psi(x))^2]$ é o erro quadrático médio.

Mensagem central:

- É possível reduzir $EQM[\hat{\psi}(x)]$ escolhendo o método de aprendizagem.
- Não temos controle sobre σ^2 . É um limite inferior para o erro de predição.

Demonstração

Substituimos $Y = \psi(x) + \epsilon$ e exploramos a independência de ϵ e $\hat{\psi}$.

$$\begin{aligned} E[(Y - \hat{\psi}(x))^2 \mid X = x] &= E[(\psi(x) + \epsilon - \hat{\psi}(x))^2 \mid X = x] \\ &= E[(\hat{\psi}(x) - \psi(x))^2] + 2 E[(\hat{\psi}(x) - \psi(x)) \cdot \epsilon] + E[\epsilon^2] \end{aligned}$$

Demonstração

Substituímos $Y = \psi(x) + \epsilon$ e exploramos a independência de ϵ e $\hat{\psi}$.

$$\begin{aligned} E[(Y - \hat{\psi}(x))^2 \mid X = x] &= E[(\psi(x) + \epsilon - \hat{\psi}(x))^2 \mid X = x] \\ &= E[(\hat{\psi}(x) - \psi(x))^2] + 2 E[(\hat{\psi}(x) - \psi(x)) \cdot \epsilon] + E[\epsilon^2] \end{aligned}$$

Como ϵ é independente dos dados de treinamento (e de $\hat{\psi}$):

$$E[(\hat{\psi}(x) - \psi(x)) \cdot \epsilon] = (E[\hat{\psi}(x)] - \psi(x)) \cdot \underbrace{E[\epsilon]}_{=0} = 0.$$

Demonstração

Substituímos $Y = \psi(x) + \epsilon$ e exploramos a independência de ϵ e $\hat{\psi}$.

$$\begin{aligned} E[(Y - \hat{\psi}(x))^2 \mid X = x] &= E[(\psi(x) + \epsilon - \hat{\psi}(x))^2 \mid X = x] \\ &= E[(\hat{\psi}(x) - \psi(x))^2] + 2 E[(\hat{\psi}(x) - \psi(x)) \cdot \epsilon] + E[\epsilon^2] \end{aligned}$$

Como ϵ é independente dos dados de treinamento (e de $\hat{\psi}$):

$$E[(\hat{\psi}(x) - \psi(x)) \cdot \epsilon] = (E[\hat{\psi}(x)] - \psi(x)) \cdot \underbrace{E[\epsilon]}_{=0} = 0.$$

Logo:

$$E[(Y - \hat{\psi}(x))^2 \mid X = x] = \underbrace{E[(\hat{\psi}(x) - \psi(x))^2]}_{\text{EQM}[\hat{\psi}(x)]} + \sigma^2.$$

Resultado

$$\text{EQM}[\hat{\psi}(x)] = \text{Viés}^2[\hat{\psi}(x)] + \text{Var}[\hat{\psi}(x)],$$

em que:

$$\text{Viés}[\hat{\psi}(x)] = \mathbb{E}[\hat{\psi}(x)] - \psi(x),$$

$$\text{Var}[\hat{\psi}(x)] = \mathbb{E}\left[(\hat{\psi}(x) - \mathbb{E}[\hat{\psi}(x)])^2\right].$$

Esta é uma das decomposições mais relevantes de toda a Aprendizagem Estatística.

Demonstração

Somamos e subtraímos $E[\hat{\psi}(x)]$ dentro do quadrado.

$$\begin{aligned} \text{EQM}[\hat{\psi}(x)] &= E[(\hat{\psi}(x) - \psi(x))^2] \\ &= E\left[\left((\hat{\psi}(x) - E[\hat{\psi}(x)]) - (\psi(x) - E[\hat{\psi}(x)])\right)^2\right] \\ &= E[(\hat{\psi}(x) - E[\hat{\psi}(x)])^2] - 2 \underbrace{(E[\hat{\psi}(x)] - E[\hat{\psi}(x)])}_{=0} \cdot (\psi(x) - E[\hat{\psi}(x)]) + (E[\hat{\psi}(x)] - \psi(x))^2 \\ &= \underbrace{\text{Var}[\hat{\psi}(x)]}_{\text{variância}} + \underbrace{(E[\hat{\psi}(x)] - \psi(x))^2}_{\text{viés}^2}. \end{aligned}$$

Combinando os resultados anteriores, obtemos

$$E[(Y - \hat{\psi}(x))^2 \mid X = x] = \underbrace{\text{Var}[\hat{\psi}(x)]}_{\text{variância}} + \underbrace{(E[\hat{\psi}(x)] - \psi(x))^2}_{\text{viés}^2} + \underbrace{\sigma^2}_{\text{erro irreduzível}}.$$

Primeiro termo: variância do método de aprendizagem

Segundo termo: viés ao quadrado do método de aprendizagem

Terceiro termo: erro irreduzível (fora do nosso controle)

Balanço viés-variância (*bias-variance trade-off*)

A variância mede o quanto $\hat{\psi}$ se modifica conforme retreinamos com novos dados.


O viés mede o quanto $\hat{\psi}$ difere, em média, da verdadeira ψ .

Observações

- Métodos mais flexíveis (aproximam variedade maior de funções de regressão): menor viés, mas maior variância.
- Métodos menos flexíveis: maior viés, porém menor variância.
- Exemplo: modelo linear para ψ não-linear $\Rightarrow$ grande viés.

É simples diminuir o viés aumentando a variância (e vice-versa). O desafio está em encontrar o equilíbrio ótimo.

Flexibilidade versus interpretabilidade



Como estimar ψ ?

Ao longo do curso, veremos diversas técnicas para estimar ψ e obter previsões para Y . Essas técnicas se dividem em duas grandes famílias:

- **Métodos paramétricos:** adotam uma forma funcional específica como *aproximação* para ψ (ex.: linear), reduzindo o problema a estimar um número finito de parâmetros. São tipicamente interpretáveis e eficientes, mas introduzem viés de modelo se a forma escolhida estiver longe da verdadeira ψ .

Como estimar ψ ?

Ao longo do curso, veremos diversas técnicas para estimar ψ e obter previsões para Y . Essas técnicas se dividem em duas grandes famílias:

- **Métodos paramétricos:** adotam uma forma funcional específica como *aproximação* para ψ (ex.: linear), reduzindo o problema a estimar um número finito de parâmetros. São tipicamente interpretáveis e eficientes, mas introduzem viés de modelo se a forma escolhida estiver longe da verdadeira ψ .
- **Métodos não paramétricos:** não impõem uma forma funcional rígida para ψ ; deixam que os *próprios dados* determinem a estrutura do modelo. Oferecem maior flexibilidade, mas exigem amostras maiores e podem ser mais difíceis de interpretar.

Para concretizar esses conceitos, examinaremos um processo de aprendizagem com dados simulados.


Preditora: X = anos de experiência, $X \sim \text{Uniforme}(8, 18)$.

Função de regressão:

$$\psi(x) = 45 \cdot \tanh\left(\frac{x}{1,9} - 7\right) + 57$$

$\epsilon \sim \text{Normal}(0, 5^2)$, independente de X .

Variável resposta: $Y = \psi(X) + \epsilon$ (salário anual, em milhares de reais).



O método de aprendizagem será uma smoothing spline (`smooth.spline()` no R).

O parâmetro graus de liberdade (`gl`) controla a flexibilidade:

`gl = 2`

Reta de mínimos quadrados ordinários.
Pouca flexibilidade.


`gl = 6`

Curva suave, adaptada aos dados.
Flexibilidade moderada.

`gl = 30`

Interpola os dados de treinamento.
Flexibilidade extrema.

Conforme aumentamos `gl`, o modelo se ajusta mais aos dados. Será que isso é sempre desejável?




Com $gl = 30$, o modelo “memoriza” os dados de treinamento.

Para cada valor de g_l :

1. Para $i = 1, \dots, M$: gere $x^{(i)}$ de F_X .
2. Para $j = 1, \dots, N$: gere dados de treinamento e ajuste $\hat{\psi}_j^{(gl)}$.
3. Aproxime $\text{Viés}^2[\hat{\psi}^{(gl)}(x^{(i)})]$ pelo quadrado da diferença entre a média dos $\hat{\psi}_j^{(gl)}(x^{(i)})$ e $\psi(x^{(i)})$.
4. Aproxime $\text{Var}[\hat{\psi}^{(gl)}(x^{(i)})]$ pela variância amostral dos $\hat{\psi}_j^{(gl)}(x^{(i)})$.
5. Viés^2 esperado $\approx \frac{1}{M} \sum_{i=1}^M \text{Viés}^2[\hat{\psi}^{(gl)}(x^{(i)})]$.
6. Variância esperada $\approx \frac{1}{M} \sum_{i=1}^M \text{Var}[\hat{\psi}^{(gl)}(x^{(i)})]$.

Isso só é possível porque estamos em cenário de simulação. Conhecemos ψ !



- O viés diminui conforme aumentamos a flexibilidade.
- A variância cresce conforme aumentamos a flexibilidade.
- O erro de predição assume formato de “U” — existe um ponto ótimo.
- Sobreajuste (*overfitting*): modelo complexo demais para ψ — ajuste perfeito no treino, erro elevado na predição.
- Subajuste (*underfitting*): modelo simples demais para capturar ψ .

Neste cenário, o equilíbrio sugere aproximadamente 6 graus de liberdade.

Por que estimar o erro de predição?

Dupla finalidade:

1. Seleção do modelo: encontrar o melhor equilíbrio viés–variância.
2. Avaliação do modelo: mensurar a performance preditiva.

Problema prático

Como ψ é desconhecida, não é possível calcular o erro de predição diretamente. É necessário estimá-lo a partir dos dados.


Como avaliar a qualidade do modelo preditivo?

Para uma $\hat{\psi}$ ajustada com dados de treinamento $(x_1, y_1), \dots, (x_n, y_n)$, define-se o EQM de treinamento:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{\psi}(x_i))^2.$$

Pergunta natural: podemos usar o EQM de treinamento para estimar o erro de predição esperado?

Como avaliar a qualidade do modelo preditivo?



Como avaliar a qualidade do modelo preditivo?

Não é possível estimar o erro de predição a partir do EQM de treinamento!

- O EQM de treinamento decresce monotonicamente com a flexibilidade.
- Um polinômio de grau 29 interpola perfeitamente $\Rightarrow$ EQM de treinamento = 0.
- Se o usássemos para escolher o modelo, selecionaríamos um modelo sobreajustado.

Comentário: Nem sempre um modelo que interpola os dados apresenta sobreajuste. Modelos de alta capacidade podem generalizar bem mesmo ajustando perfeitamente os dados de treinamento, fenômeno discutido por Belkin, Hsu e Mitra (*NeurIPS*, 2018)

Como avaliar a qualidade do modelo?

Vimos que estimar o EQM através do conjunto de treinamento leva a uma estimativa otimista do erro de predição esperado.


Precisamos de uma abordagem melhor. Veremos duas:


- *Data splitting*
- Validação cruzada (*cross-validation*)

Data splitting

Os dados são divididos aleatoriamente em dois conjuntos:

- Treinamento: ajuste do modelo.
- Teste: avaliação do erro de predição.





Validação cruzada tirando-um-fora (LOOCV)

Para $i = 1, \dots, n$:


1. Remova o par (x_i, y_i) dos dados de treinamento.
2. Ajuste $\hat{\psi}_{(\setminus i)}$ com os $n - 1$ dados restantes.
3. Calcule $\text{eqm}_i = (y_i - \hat{\psi}_{(\setminus i)}(x_i))^2$.

A estimativa LOOCV para o erro de predição esperado é:

$$\text{CV}_{(n)} = \frac{1}{n} \sum_{i=1}^n \text{eqm}_i.$$

Cada observação desempenha o papel de “teste” exatamente uma vez.

k -fold CV



Exemplo com $k = 5$ lotes. As observações são aleatorizadas antes da divisão; cada lote serve como teste exatamente uma vez.

Validação cruzada em k lotes (k -fold CV)

1. Divida aleatoriamente os dados em k lotes de tamanho $\approx n/k$.
2. Para $i = 1, \dots, k$: remova o i -ésimo lote, ajuste $\hat{\psi}_{(\setminus i)}$ com o restante, e calcule

$$\text{eqm}_i = \frac{1}{|\text{lote}_i|} \sum_{(x_j, y_j) \in \text{lote}_i} (y_j - \hat{\psi}_{(\setminus i)}(x_j))^2.$$

A estimativa k -fold CV:

$$\text{CV}_{(k)} = \frac{1}{k} \sum_{i=1}^k \text{eqm}_i.$$

LOOCV vs. k -fold CV

Observe que LOOCV corresponde ao caso particular $k = n$.

LOOCV apresenta maior custo computacional (o modelo é ajustado n vezes).

Há, porém, outra vantagem do k -fold CV (menos óbvia):

No LOOCV, os conjuntos de treinamento são muito semelhantes ($n - 1$ pontos em comum), induzindo forte correlação entre os eqm_i 's. Isso infla a variância da estimativa:

$$\text{Var}[\text{CV}_{(n)}] = \frac{1}{n^2} \sum_{i=1}^n \text{Var}[\text{EQM}_i] + \frac{2}{n^2} \sum_{i < j} \text{Cov}[\text{EQM}_i, \text{EQM}_j].$$

Recomendação prática: $k = 5$ ou $k = 10$ oferecem bom compromisso entre viés, variância e custo computacional.

Fundamentos

- Alvo: estimar $\psi(x) = E[Y \mid X = x]$.
- Erro de predição = $\text{Viés}^2 + \text{Variância} + \sigma^2$.
- Maior flexibilidade: menor viés, maior variância.

Estimação do erro de predição

- EQM de treinamento é otimista.
- *Data splitting*: treino e teste separados.
- LOOCV e k -fold CV: cada observação serve de teste.
- k -fold ($k = 5$ ou 10): melhor balanço na prática.

O Oráculo de Delfos e o Aprendizado Estatístico

“Se eu atravessar o rio Hális e atacar os persas, o que acontecerá?”

Creso, rei da Lídia, ao Oráculo de Delfos

“Um grande império será destruído.”

O Oráculo de Delfos

Creso foi derrotado. O império destruído era o dele. O oráculo não errou.

O oráculo nunca mente. Creso generalizou mal

Creso e o Overfitting

Amostra pequena + viés do analista $\Rightarrow$ gap de generalização.

A Profecia Ambígua

$F_{Y|X}$ tem variância positiva.

O erro se decompõe em:

$$\text{erro}_{\text{reduzível}} + \text{erro}_{\text{irreduzível}}$$

Conhece-te a ti mesmo Um

bom analista prediz e quantifica a incerteza associada às predições:

$$P(Y \in C(X)) \geq 1 - \alpha$$

Da regressão à classificação

Na regressão, o problema central era estimar $\psi(x) = E[Y \mid X = x]$ sob perda quadrática.

Na classificação, o cenário muda:

Regressão

- $Y \in \mathbb{R}$
- Perda quadrática: $(Y - \psi(X))^2$
- Solução ótima: $\psi(x) = E[Y \mid X = x]$

Classificação

- $Y \in \{0, 1\}$
- Perda 0-1: $\mathbb{I}_{\{\varphi(X) \neq Y\}}$
- Solução ótima: classificador de Bayes, baseado em $\eta(x) = \Pr\{Y=1 \mid X=x\}$

Nos dois casos, a estrutura é a mesma: definir uma função de perda, encontrar a regra ótima, e estimá-la a partir dos dados.

Classificação

Um problema de classificação


Dados: 2000 clientes de um banco.

Preditores: Idade e Renda média mensal (em salários mínimos).

Variável resposta: Utilizou o cheque especial por mais de 21 dias no último ano? (Sim ou Não).

Um classificador é uma regra que, para um novo cliente, prediz a classe a partir de suas preditoras.

Um problema de classificação



Temos $X \in \mathbb{R}^p$, $Y \in C = \{0, 1, \dots, c\}$, e queremos um classificador $\varphi : \mathbb{R}^p \rightarrow C$.

Caso binário (sem perda de generalidade): $C = \{0, 1\}$.

Tratamos novamente (X, Y) como vetor aleatório com distribuição conjunta $F_{X,Y}$ desconhecida.

O erro de classificação esperado de um classificador φ é:

$$\Pr\{\varphi(X) \neq Y\} = \mathbb{E}[\mathbb{I}_{\{\varphi(X) \neq Y\}}].$$

Conexão com regressão:

- Regressão: função de perda quadrática $(Y - \psi(X))^2$.
- Classificação: função de perda 0-1 $\mathbb{I}_{\{\varphi(X) \neq Y\}}$.

Classificador de Bayes

Defina o classificador de Bayes:

$$\varphi^*(x) = \begin{cases} 1 & \text{se } \Pr\{Y = 1 \mid X = x\} =: \eta(x) > 1/2, \\ 0 & \text{caso contrário.} \end{cases}$$

O classificador de Bayes tem um papel formal: em um problema real não conhecemos $\eta(x)$ e não conseguimos construir φ^* .

O erro de φ^* é denominado erro de Bayes: é o menor erro possível.

Resultado O classificador de Bayes é ótimo: para qualquer classificador φ ,

$$\Pr\{\varphi^*(X) \neq Y\} \leq \Pr\{\varphi(X) \neq Y\}.$$

Demonstração

Para qualquer classificador φ e $x \in \mathbb{R}^p$:

$$\Pr\{\varphi(X) = Y \mid X = x\} = \begin{cases} 1 - \eta(x) & \text{se } \varphi(x) = 0, \\ \eta(x) & \text{se } \varphi(x) = 1. \end{cases}$$

Demonstração

Para qualquer classificador φ e $x \in \mathbb{R}^p$:

$$\Pr\{\varphi(X) = Y \mid X = x\} = \begin{cases} 1 - \eta(x) & \text{se } \varphi(x) = 0, \\ \eta(x) & \text{se } \varphi(x) = 1. \end{cases}$$

Reescrevendo (usando $I_{\{\varphi(x)=0\}} = 1 - I_{\{\varphi(x)=1\}}$):

$$\begin{aligned} \Pr\{\varphi(X) \neq Y \mid X = x\} &= 1 - \Pr\{\varphi(X) = Y \mid X = x\} \\ &= 1 - [I_{\{\varphi(x)=0\}}(1 - \eta(x)) + I_{\{\varphi(x)=1\}}\eta(x)] \\ &= \eta(x) - (2\eta(x) - 1) I_{\{\varphi(x)=1\}}. \end{aligned}$$

Demonstração

Para qualquer classificador φ e $x \in \mathbb{R}^p$:

$$\Pr\{\varphi(X) = Y \mid X = x\} = \begin{cases} 1 - \eta(x) & \text{se } \varphi(x) = 0, \\ \eta(x) & \text{se } \varphi(x) = 1. \end{cases}$$

Reescrevendo (usando $I_{\{\varphi(x)=0\}} = 1 - I_{\{\varphi(x)=1\}}$):

$$\begin{aligned} \Pr\{\varphi(X) \neq Y \mid X = x\} &= 1 - \Pr\{\varphi(X) = Y \mid X = x\} \\ &= 1 - [I_{\{\varphi(x)=0\}}(1 - \eta(x)) + I_{\{\varphi(x)=1\}}\eta(x)] \\ &= \eta(x) - (2\eta(x) - 1) I_{\{\varphi(x)=1\}}. \end{aligned}$$

Subtraindo os erros:

$$\Pr\{\varphi(X) \neq Y \mid X=x\} - \Pr\{\varphi^*(X) \neq Y \mid X=x\} = (2\eta(x) - 1)(I_{\{\varphi^*(x)=1\}} - I_{\{\varphi(x)=1\}}).$$

Demonstração

Analizamos dois casos pela definição de φ^* :

Caso 1: $\varphi^*(x) = 0 \Rightarrow \eta(x) \leq 1/2 \Rightarrow 2\eta(x) - 1 \leq 0$ e $I_{\{\varphi^*(x)=1\}} - I_{\{\varphi(x)=1\}} \leq 0$.

$\Rightarrow$ Produto ≥ 0 . ✓

Caso 2: $\varphi^*(x) = 1 \Rightarrow \eta(x) > 1/2 \Rightarrow 2\eta(x) - 1 > 0$ e $I_{\{\varphi^*(x)=1\}} - I_{\{\varphi(x)=1\}} \geq 0$.

$\Rightarrow$ Produto ≥ 0 . ✓

Demonstração

Analisamos dois casos pela definição de φ^* :

Caso 1: $\varphi^*(x) = 0 \Rightarrow \eta(x) \leq 1/2 \Rightarrow 2\eta(x) - 1 \leq 0$ e $I_{\{\varphi^*(x)=1\}} - I_{\{\varphi(x)=1\}} \leq 0$.

$\Rightarrow$ Produto ≥ 0 . ✓

Caso 2: $\varphi^*(x) = 1 \Rightarrow \eta(x) > 1/2 \Rightarrow 2\eta(x) - 1 > 0$ e $I_{\{\varphi^*(x)=1\}} - I_{\{\varphi(x)=1\}} \geq 0$.

$\Rightarrow$ Produto ≥ 0 . ✓

Conclusão: Em ambos os casos, $\Pr\{\varphi(X) \neq Y \mid X = x\} - \Pr\{\varphi^*(X) \neq Y \mid X = x\} \geq 0$.

Integrando sobre $dF_X(x)$:

$$\Pr\{\varphi(X) \neq Y\} = \int \Pr\{\varphi(X) \neq Y \mid X = x\} dF_X(x) \geq \Pr\{\varphi^*(X) \neq Y\}.$$

k vizinhos mais próximos (k -NN)

Dada uma função de distância em $\mathbb{R}^p$, o classificador k -NN:

1. Determina os k pontos de treinamento mais próximos de x .
2. Classifica x como a classe mais frequente entre os k vizinhos (voto da maioria).


Resultado de Cover e Hart (1967) Assintoticamente, o erro da regra 1-NN nunca excede o dobro do erro de Bayes, de maneira universal (para qualquer $F_{X,Y}$).

Escolha de k :

- Não podemos usar a taxa de erro de treinamento (com $k = 1$, o erro de treinamento é 0!).
- Escolhemos k via validação cruzada.

Variante para regressão: ao invés do voto da maioria, toma-se a *média* das respostas dos k vizinhos.

Escolhendo k via validação cruzada



O papel de k no classificador k -NN é análogo aos graus de liberdade na *smoothing spline*:

k **pequeno** (ex.: $k = 1$)

- Fronteira de decisão irregular.
- Baixo viés, alta variância.
- Análogo a gl grande na regressão.

k **grande** (ex.: $k = 100$)

- Fronteira de decisão suave.
- Alto viés, baixa variância.
- Análogo a gl pequeno na regressão.

Classificador com $k = 1$ vs. $k = 25$

