

Lista de Exercícios I

Fundamentos de Aprendizagem Supervisionada

Exercício 1. Classifique os seguintes problemas como regressão ou classificação e identifique as possíveis preditoras e a variável resposta:

- (a) Uma fintech deseja prever se um cliente entrará em inadimplência no próximo mês com base em histórico de pagamentos, renda e idade.
- (b) Uma rede de restaurantes deseja prever o faturamento semanal de cada unidade com base na localização, número de funcionários e avaliação online.
- (c) Um sistema de saúde quer classificar exames de imagem em {normal, benigno, maligno} usando atributos extraídos das imagens.
- (d) Pesquisadores querem estimar a concentração de CO₂ atmosférico a partir de dados de satélite.

Exercício 2. Considere o par aleatório (X, Y) com distribuição conjunta desconhecida. Seja $\psi(x) = \mathbb{E}[Y \mid X = x]$ a função de regressão.

- (a) Explique, em suas próprias palavras, por que $\psi(x)$ minimiza $\mathbb{E}[(Y - \psi(X))^2]$.
- (b) Se $Y = 3X + 2 + \varepsilon$, com ε independente de X e $\mathbb{E}[\varepsilon] = 0$, qual é $\psi(x)$?
- (c) Neste mesmo modelo, qual é o erro de predição esperado $\mathbb{E}[(Y - \psi(X))^2]$?

Exercício 3. Seja $\hat{\psi}(\mathbf{x}) = \mathbf{x}^\top \hat{\boldsymbol{\beta}}$, com $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$ o estimador de mínimos quadrados ordinários em um modelo de regressão linear.

- (a) Mostre que, para um ponto fixo $\mathbf{x}_0 \in \mathbb{R}^p$:

$$\text{Viés}[\hat{\psi}(\mathbf{x}_0)] = \mathbf{x}_0^\top E(\hat{\boldsymbol{\beta}}) - \psi(\mathbf{x}_0),$$

Quando esse viés é zero?

- (b) Calcule $\text{Var}[\hat{\psi}(\mathbf{x}_0)]$ e mostre que é igual a $\sigma^2 \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$.
- (c) Discuta qualitativamente o que acontece com o viés e a variância quando adicionamos mais preditoras ao modelo.

Exercício 4. Classifique cada afirmação como verdadeira ou falsa e justifique brevemente:

- (a) Um modelo com alto viés necessariamente possui baixa variância.
- (b) O erro irreduzível depende da escolha do método de aprendizagem.
- (c) Se dobrarmos o tamanho da amostra de treinamento, o erro irreduzível diminui pela metade.
- (d) O EQM de treinamento sempre subestima o erro de predição esperado.
- (e) Um modelo que interpola perfeitamente os dados de treinamento tem EQM de treinamento igual a zero.

Exercício 5. Considere dois estimadores para $\psi(x)$:

- $\hat{\psi}_A$: $\text{Viés}^2 = 25$, $\text{Var} = 4$.
- $\hat{\psi}_B$: $\text{Viés}^2 = 1$, $\text{Var} = 50$.

- Calcule o EQM de cada estimador. Qual é preferível sob o critério do EQM?
- Suponha que $\sigma^2 = 10$. Calcule o erro de predição total para cada estimador. A conclusão muda?
- Em que cenário prático você optaria pelo estimador com maior viés? Justifique.

Exercício 6.

- Explique por que o EQM de treinamento decresce monotonicamente com a flexibilidade do modelo e, portanto, não pode ser usado para estimar o erro de predição.
- No procedimento LOOCV, cada observação serve como “teste” exatamente uma vez. Explique por que isso torna a estimativa aproximadamente não viesada para o erro de predição.

Exercício 7. Utilizando os dados `Boston` (ou o conjunto `ISLR2::Boston` no R):

- Ajuste modelos polinomiais de grau $d = 1, 2, \dots, 10$ usando `lstat` como preditora e `medv` como resposta.
- Calcule o EQM de treinamento para cada grau. Plote o gráfico.
- Implemente a validação cruzada 10-fold CV para cada grau polinomial. Plote a curva de CV em função do grau.
- Compare os gráficos de (b) e (c). Qual grau polinomial é selecionado por cada critério? Discuta.

Dica: No R, use as funções `glm()` e `cv.glm()` do pacote `boot`, ou implemente a CV manualmente com um loop sobre os lotes.

Exercício 8. Neste exercício você implementará a validação cruzada do zero, sem usar funções prontas.

- Escreva uma função em R (ou Python) que receba um data frame, um valor de k e um grau polinomial d , e retorne a estimativa k -fold CV do erro de predição.
- Aplique sua função aos dados Boston, com `medv ~ poly(lstat, d)`, para $d = 1, \dots, 8$ e $k \in \{5, 10, n\}$. Compare os resultados.
- Repita (b) 100 vezes (com diferentes partições aleatórias) e plote boxplots do erro CV para cada configuração (d, k) . O que você observa sobre a variabilidade da estimativa para diferentes valores de k ?

Exercício 9. Para cada cenário, indique se o objetivo principal é predição ou inferência e sugira um nível de flexibilidade (baixo, moderado ou alto):

- Uma seguradora deseja entender quais fatores mais influenciam o custo de sinistros.
- Uma plataforma de streaming quer recomendar filmes para cada usuário.
- Um epidemiologista quer medir o efeito de uma vacina sobre a taxa de hospitalização.

- (d) Um banco deseja construir um sistema automático de aprovação de crédito.

Exercício 10. Na aula, vimos que a perda quadrática leva à esperança condicional como função de regressão ótima. Em problemas de classificação, usamos a perda 0-1:

$$L(\varphi(x), y) = \mathbb{I}(y \neq \psi(x)),$$

onde $Y \in \{0, 1, \dots, c\}$.

- (a) Mostre que o classificador que minimiza $\mathbb{E}[L(Y, \psi(X))]$ é o classificador de Bayes:

$$\psi^*(x) = \operatorname{argmax}_k P(Y = k \mid X = x).$$

- (b) Qual é o análogo da decomposição “erro redutível + erro irredutível” no contexto de classificação?
- (c) Suponha $P(Y = 0 \mid X = x) = 0.3$, $P(Y = 1 \mid X = x) = 0.5$, $P(Y = 2 \mid X = x) = 0.2$. Qual classe $\psi^*(x)$ escolheria o classificador de Bayes? Calcule o erro irredutível nesse ponto x .
- (d) Para um x' com $P(Y = k \mid X = x') = 1/c$ para todo k , qual é o erro irredutível? O que isso diz sobre a dificuldade do problema?

Exercício 11. Usando os dados `Default` do pacote `ISLR2` (resposta: `default`; preditoras: `balance`, `income`, `student`):

- (a) Ajuste uma regressão logística e calcule a taxa de erro de classificação no treinamento.
- (b) Implemente 10-fold CV e calcule a taxa de erro de classificação por CV. Compare com o item (a).
- (c) Investigue o efeito de usar apenas `balance` como preditora versus usar todas as preditoras. A inclusão de `income` e `student` melhora a predição?
- (d) Discuta: neste problema, o objetivo é mais voltado para predição ou inferência? Como isso afeta a escolha do modelo?