

Lista de Exercícios II

Regressão linear, seleção de variáveis, regularização e métodos não-paramétricos

Exercício 1. Indique se cada afirmação é verdadeira ou falsa, justificando brevemente sua resposta.

- (a) Se o modelo de regressão linear não está corretamente especificado, ele é inútil para predição.
- (b) O EQM de treino é sempre menor ou igual ao EQM de teste.
- (c) Aumentar o número de preditores sempre melhora o poder preditivo.
- (d) A regressão Ridge pode zerar exatamente coeficientes, sendo útil para seleção de variáveis.
- (e) No método KNN, valores pequenos de k produzem estimadores com baixo viés e alta variância.

Exercício 2. Considere o modelo de regressão linear $\hat{\psi}(\mathbf{x}) = \mathbf{x}^\top \hat{\boldsymbol{\beta}}$ e a amostra de treinamento $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$, com $\mathbf{x}_i \in \mathbb{R}^{p+1}$ (incluindo o intercepto).

- (a) Escreva a função que o estimador de mínimos quadrados minimiza.
- (b) Mostre que o estimador de mínimos quadrados é dado por $\hat{\boldsymbol{\beta}} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{Y}$.
- (c) Sob quais condições $\mathbb{X}^\top \mathbb{X}$ é inversível?

Exercício 3. Considere o modelo verdadeiro $Y = \sin(X) + \varepsilon$, com $\varepsilon \sim N(0, \sigma^2)$ e $X \sim \text{Uniforme}(0, 2\pi)$. Com uma amostra de treinamento de tamanho n , ajustamos regressões polinomiais de grau p :

$$\hat{\psi}_p(x) = \hat{\beta}_0 + \hat{\beta}_1 x + \dots + \hat{\beta}_p x^p.$$

- (a) Para $p = 1$, o modelo é capaz de captar a forma senoidal de $\psi(x)$? Esse modelo terá viés alto ou baixo? E a variância?
- (b) Para $p = 15$ e $n = 30$, o que é esperado em termos de viés e variância? E quanto ao risco?
- (c) Explique como a validação cruzada ajuda a escolher o valor ótimo de p .
- (d) Por que o EQM de treino *não* pode ser usado para selecionar p ?

Exercício 4. Considere um problema de regressão com $p = 100$ covariáveis, $n = 200$ observações, e sabe-se que apenas cerca de 5 covariáveis são relevantes.

- (a) Dentre Ridge, Lasso e mínimos quadrados com forward stepwise, qual método você escolheria? Justifique em termos de viés e variância.
- (b) Um colega sugere usar, para seleção de variáveis, o método de busca pelo melhor subconjunto (*best subset selection*). Comente a viabilidade.
- (c) Outro colega sugere usar a regressão Ridge e, após o ajuste, descartar variáveis cujo coeficiente estimado é menor do que 0,01 em valor absoluto. Há algum problema com essa abordagem?

Exercício 5. Suponha que as colunas de $\mathbb{X}$ são ortonormais, isto é, $\mathbb{X}^\top \mathbb{X} = \mathbf{I}$, e seja $\hat{\boldsymbol{\beta}}^{\text{OLS}} = \mathbb{X}^\top \mathbb{Y}$ o estimador de mínimos quadrados.

- (a) Mostre que, neste caso, o estimador Ridge é dado por $\hat{\beta}_j^{\text{ridge}} = \frac{\hat{\beta}_j^{\text{OLS}}}{1+\lambda}$, para $j = 1, \dots, p$. Comparando os estimadores, o que é possível concluir sobre o efeito de λ nos coeficientes?
- (b) Calcule $\text{Var}(\hat{\beta}_j^{\text{ridge}})$ em função de $\text{Var}(\hat{\beta}_j^{\text{OLS}})$ e λ . É possível estabelecer uma comparação entre essas variâncias?
- (c) No caso ortogonal, demonstra-se que o estimador Lasso é dado por:

$$\hat{\beta}_j^{\text{lasso}} = \text{sign}(\hat{\beta}_j^{\text{OLS}}) \left(|\hat{\beta}_j^{\text{OLS}}| - \lambda/2 \right)_+,$$

em que $\text{sign}(x)$ denota a função sinal, definida por:

$$\text{sign}(x) = \begin{cases} +1, & \text{se } x > 0, \\ 0, & \text{se } x = 0, \\ -1, & \text{se } x < 0, \end{cases}$$

e $(a)_+ = \max\{a, 0\}$ representa a parte positiva de $a \in \mathbb{R}$. Compare qualitativamente o comportamento de Ridge e Lasso: o que cada um faz com coeficientes pequenos? *Dica:* esboce o gráfico dos estimadores Ridge e Lasso em função da solução obtida por mínimos quadrados.

Exercício 6. Considere um preditor medido em duas escalas: x em metros e $\tilde{x} = x/1000$ em quilômetros. Suponha que o modelo verdadeiro seja

$$Y = 3x + \epsilon.$$

- (a) Reescreva o modelo em termos de $\tilde{x}$ e identifique o coeficiente associado a esse preditor. Comente como a mudança de escala afeta a magnitude do coeficiente.
- (b) Considere agora um modelo de regressão linear múltipla com dois preditores em escalas muito distintas (por exemplo, um em metros e outro em quilômetros). Na regressão Ridge, o termo de penalização tem a forma $\lambda(\beta_1^2 + \beta_2^2)$. Discuta qual dos coeficientes tende a sofrer maior penalização quando os preditores não são padronizados e avalie se esse comportamento é desejável.
- (c) Explique de que forma a padronização dos preditores mitiga o problema discutido em (b).

Exercício 7. Considere o conjunto de treinamento abaixo, gerado segundo $Y = \psi(X) + \varepsilon$:

i	1	2	3	4	5
x_i	-2	-1	0	1	2
y_i	5	2	2	1	6

- (a) Ajuste uma regressão polinomial de grau $J = 0$ (apenas intercepto). Escreva $\hat{\psi}_0(x)$ e calcule o RSS no treinamento.
- (b) Ajuste uma regressão polinomial de grau $J = 1$. Escreva $\hat{\psi}_1(x)$ e calcule o RSS.
- (c) Ajuste uma regressão polinomial de grau $J = 2$. Compare o RSS com os obtidos em (a) e (b). O que se pode dizer sobre o comportamento do RSS de treinamento à medida que J cresce?
- (d) Argumente, sem fazer contas, que com $J = 4$ obtemos $\text{RSS} = 0$. Por que isso *não* significa que $J = 4$ é a melhor escolha?
- (e) Use *leave-one-out cross-validation* (LOOCV) para comparar $J = 0$ e $J = 1$. Qual modelo seria selecionado?

Exercício 8. Considere o conjunto de treinamento abaixo, com $n = 5$ observações e uma variável preditora:

i	1	2	3	4	5
x_i	1	3	6	8	10
y_i	2	6	5	7	3

Queremos estimar $\psi(x_0)$ no ponto $x_0 = 4$.

- (a) Calcule $\hat{\psi}(4)$ usando o estimador de Nadaraya–Watson com *kernel uniforme* e banda $h = 2$, isto é,

$$K(x, x_i) = \mathbb{I}(|x - x_i| \leq h).$$

- (b) Calcule $\hat{\psi}(4)$ usando o *kernel gaussiano* com banda $h = 1$:

$$K(x, x_i) = \frac{1}{\sqrt{2\pi}h} \exp\left(-\frac{(x - x_i)^2}{2h^2}\right).$$

- (c) Compare com o estimador KNN com $k = 3$ no mesmo ponto. Qual é a diferença conceitual entre os pesos atribuídos por cada método?
- (d) O que acontece com $\hat{\psi}(4)$ no item (a) quando $h \rightarrow \infty$? E quando $h \rightarrow 0^+$?