

Regressão Linear sob a ótica preditivista

Mineração de Dados

Helton Graziadei

Por que estudar regressão linear?

- É a base de muitos métodos mais avançados (Lasso, Ridge, GAM, GLM, dentre outros).
- Ferramenta simples e interpretável para predição e inferência.
- Compreender seus pontos fortes e limitações é essencial antes de avançar.
- Na abordagem preditivista, não é necessário que o modelo esteja correto para que ele seja útil.

Recordando a notação: Queremos estimar

$$\psi(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}].$$

com base em uma amostra de treinamento $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ (i.i.d.)

Recordando a notação: Queremos estimar

$$\psi(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}].$$

com base em uma amostra de treinamento $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ (i.i.d.)

Dois objetivos possíveis:

Inferencial Quais preditores são importantes? Qual o efeito de mudar x_j sobre Y ? Testes de hipótese, intervalos de confiança.

Recordando a notação: Queremos estimar

$$\psi(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}].$$

com base em uma amostra de treinamento $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ (i.i.d.)

Dois objetivos possíveis:

Inferencial Quais preditores são importantes? Qual o efeito de mudar x_j sobre Y ? Testes de hipótese, intervalos de confiança.

Preditivo Como construir $\hat{\psi} : \mathbb{R}^p \rightarrow \mathbb{R}$ tal que, para novas observações,

$$\hat{\psi}(\mathbf{x}_{n+1}) \approx y_{n+1}, \quad \dots, \quad \hat{\psi}(\mathbf{x}_{n+m}) \approx y_{n+m} ?$$

Recordando a notação: Queremos estimar

$$\psi(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}].$$

com base em uma amostra de treinamento $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ (i.i.d.)

Dois objetivos possíveis:

Inferencial Quais preditores são importantes? Qual o efeito de mudar x_j sobre Y ? Testes de hipótese, intervalos de confiança.

Preditivo Como construir $\hat{\psi} : \mathbb{R}^p \rightarrow \mathbb{R}$ tal que, para novas observações,

$$\hat{\psi}(\mathbf{x}_{n+1}) \approx y_{n+1}, \quad \dots, \quad \hat{\psi}(\mathbf{x}_{n+m}) \approx y_{n+m} ?$$

Nosso foco está na segunda abordagem: buscamos estimar $\psi(\mathbf{x})$ sem assumir que nosso modelo ajustado contém a verdadeira função de regressão.

Para medir a qualidade de uma função ψ , usamos o erro de predição esperado (ou risco quadrático):

$$R(\psi) = \mathbb{E}[(Y - \psi(\mathbf{X}))^2],$$

em que $(\mathbf{X}, Y)$ é uma nova observação (não usada para estimar ψ).

Para medir a qualidade de uma função ψ , usamos o erro de predição esperado (ou risco quadrático):

$$R(\psi) = \mathbb{E}[(Y - \psi(\mathbf{X}))^2],$$

em que $(\mathbf{X}, Y)$ é uma nova observação (não usada para estimar ψ).

Quanto menor o risco, melhor a função de predição.

Regressão linear múltipla

Adota uma forma linear para estimar ψ , utilizando p covariáveis:

$$\psi_{\beta}(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

Regressão linear múltipla

Adota uma forma linear para estimar ψ , utilizando p covariáveis:

$$\psi_{\beta}(\mathbf{x}) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

Em forma matricial:

$$\psi_{\beta}(\mathbf{x}) = \mathbf{x}^{\top} \boldsymbol{\beta},$$

em que

$$\mathbf{x} = \begin{pmatrix} 1 \\ x_1 \\ \vdots \\ x_p \end{pmatrix} \in \mathbb{R}^{p+1} \quad \text{e} \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} \in \mathbb{R}^{p+1}.$$

Estimador de mínimos cuadrados

Estimamos $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ minimizando:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2.$$

Estimador de mínimos quadrados

Estimamos $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ minimizando:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2.$$

A solução em forma fechada:

$$\boxed{\hat{\beta} = (\mathbb{X}^{\top} \mathbb{X})^{-1} \mathbb{X}^{\top} \mathbb{Y},}$$

em que

$$\mathbb{X} = \begin{pmatrix} \mathbf{x}_1^{\top} \\ \vdots \\ \mathbf{x}_n^{\top} \end{pmatrix} = \begin{pmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & \cdots & x_{n,p} \end{pmatrix} \quad \text{e} \quad \mathbb{Y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

Estimador de mínimos quadrados

Estimamos $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ minimizando:

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n (y_i - \mathbf{x}_i^{\top} \beta)^2.$$

A solução em forma fechada:

$$\boxed{\hat{\beta} = (\mathbb{X}^{\top} \mathbb{X})^{-1} \mathbb{X}^{\top} \mathbb{Y},}$$

em que

$$\mathbb{X} = \begin{pmatrix} \mathbf{x}_1^{\top} \\ \vdots \\ \mathbf{x}_n^{\top} \end{pmatrix} = \begin{pmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n,1} & \cdots & x_{n,p} \end{pmatrix} \quad \text{e} \quad \mathbb{Y} = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix}.$$

Na prática, usamos R:

```
lm(sales ~ TV + radio + newspaper, data = Advertising)
```

A função de regressão estimada

A função de regressão estimada é:

$$\hat{\psi}(\mathbf{x}) = \mathbf{x}^T \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p.$$

A função de regressão estimada

A função de regressão estimada é:

$$\hat{\psi}(\mathbf{x}) = \mathbf{x}^T \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p.$$

Interpretação preditivista: $\hat{\psi}(\mathbf{x})$ é a nossa melhor aproximação *linear* para $\psi(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$.

A função de regressão estimada

A função de regressão estimada é:

$$\hat{\psi}(\mathbf{x}) = \mathbf{x}^T \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p.$$

Interpretação preditivista: $\hat{\psi}(\mathbf{x})$ é a nossa melhor aproximação *linear* para $\psi(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$.

Sob a cultura estatística, o foco seria interpretar cada $\hat{\beta}_j$, fazer testes de hipóteses, verificar suposições, etc.

A função de regressão estimada

A função de regressão estimada é:

$$\hat{\psi}(\mathbf{x}) = \mathbf{x}^T \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_p x_p.$$

Interpretação preditivista: $\hat{\psi}(\mathbf{x})$ é a nossa melhor aproximação *linear* para $\psi(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$.

Sob a cultura estatística, o foco seria interpretar cada $\hat{\beta}_j$, fazer testes de hipóteses, verificar suposições, etc.

Sob a cultura do preditivista, o foco está em: $\hat{\psi}$ prediz bem novas observações? E o que a teoria nos diz sobre a qualidade do estimador de mínimos quadrados?

Mínimos quadrados: um pouco de teoria

O estimador de mínimos quadrados possui algumas propriedades interessantes:

- Consistência (convergência em probabilidade) assumindo linearidade, homoscedasticidade e normalidade.
- Melhor estimador linear não viesado (BLUE) sob linearidade e homoscedasticidade.

Mas podemos obter garantias mesmo sem tais suposições!

Mínimos quadrados quando a linearidade falha

A suposição de linearidade muitas vezes não é válida.

Mínimos quadrados quando a linearidade falha

A suposição de linearidade muitas vezes não é válida.

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \mathbf{x}^\top \beta)^2] : \text{melhor preditor linear}$$

Mínimos quadrados quando a linearidade falha

A suposição de linearidade muitas vezes não é válida.

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \mathbf{x}^\top \beta)^2] : \text{melhor preditor linear}$$

Mesmo quando ψ não é linear, o estimador de mínimos quadrados converge para o melhor preditor linear β^* .

Mínimos quadrados quando a linearidade falha

A suposição de linearidade muitas vezes não é válida.

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \mathbf{x}^\top \beta)^2] : \text{melhor preditor linear}$$

Mesmo quando ψ não é linear, o estimador de mínimos quadrados converge para o melhor preditor linear β^* .

Mínimos quadrados quando a linearidade falha

A suposição de linearidade muitas vezes não é válida.

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \mathbf{x}^\top \beta)^2] : \text{melhor preditor linear}$$

Mesmo quando ψ não é linear, o estimador de mínimos quadrados converge para o melhor preditor linear β^* .

Ou seja: $\mathbf{x}^\top \beta^*$ é a função linear com menor erro de teste (esperado), *mesmo que $\psi(\mathbf{x})$ não seja linear*.

Mínimos quadrados quando a linearidade falha

A suposição de linearidade muitas vezes não é válida.

$$\beta^* = \arg \min_{\beta} \mathbb{E}[(Y - \mathbf{x}^\top \beta)^2] : \text{melhor preditor linear}$$

Mesmo quando ψ não é linear, o estimador de mínimos quadrados converge para o melhor preditor linear β^* .

Ou seja: $\mathbf{x}^\top \beta^*$ é a função linear com menor erro de teste (esperado), *mesmo que $\psi(\mathbf{x})$ não seja linear*.

⇒ Mínimos quadrados podem ser úteis mesmo sob especificação incorreta do modelo!

Por que isso funciona?

Teorema

1. $\hat{\beta} \xrightarrow{P} \beta^*$.
2. $R(\psi_{\hat{\beta}}) \rightarrow R(\psi_{\beta^*})$

Por que isso funciona?

Teorema

1. $\hat{\beta} \xrightarrow{P} \beta^*$.
2. $R(\psi_{\hat{\beta}}) \rightarrow R(\psi_{\beta^*})$

Consequências:

- Mesmo que $\psi(\mathbf{x})$ não seja linear, o risco do estimador de MQ converge para o risco do melhor preditor linear.

Por que isso funciona?

Teorema

1. $\hat{\beta} \xrightarrow{P} \beta^*.$
2. $R(\psi_{\hat{\beta}}) \rightarrow R(\psi_{\beta^*})$

Consequências:

- Mesmo que $\psi(\mathbf{x})$ não seja linear, o risco do estimador de MQ converge para o risco do melhor preditor linear.
- Não precisamos que o modelo esteja correto para que as predições sejam boas. Basta que a aproximação linear tenha risco razoável.

Regressão polinomial

Para captar relações não-lineares em x mantendo a estrutura de regressão linear em β , podemos usar

$$\psi_p(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_p x^p.$$

Regressão polinomial

Para captar relações não-lineares em x mantendo a estrutura de regressão linear em β , podemos usar

$$\psi_p(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_p x^p.$$

- Continua sendo regressão linear múltipla, com $X_1 = x$, $X_2 = x^2$, $\dots$, $X_p = x^p$.
- O grau p controla a complexidade do modelo.

Regressão polinomial

Para captar relações não-lineares em x mantendo a estrutura de regressão linear em β , podemos usar

$$\psi_p(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_p x^p.$$

- Continua sendo regressão linear múltipla, com $X_1 = x$, $X_2 = x^2$, $\dots$, $X_p = x^p$.
- O grau p controla a complexidade do modelo.
- Balanço viés–variância:
 - p pequeno $\Rightarrow$ viés alto, variância baixa.
 - p grande $\Rightarrow$ viés baixo, variância alta.

Regressão polinomial

Para captar relações não-lineares em x mantendo a estrutura de regressão linear em β , podemos usar

$$\psi_p(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_p x^p.$$

- Continua sendo regressão linear múltipla, com $X_1 = x$, $X_2 = x^2$, $\dots$, $X_p = x^p$.
- O grau p controla a complexidade do modelo.
- Balanço viés–variância:
 - p pequeno $\Rightarrow$ viés alto, variância baixa.
 - p grande $\Rightarrow$ viés baixo, variância alta.

Como escolher p ?

Seleção do grau via *data splitting*

Queremos selecionar o melhor modelo dentro da classe

$$\Psi = \left\{ \psi_p(\mathbf{x}) = \beta_0 + \sum_{j=1}^p \beta_j x^j, \quad p \in \{1, 2, \dots, P_{\max}\} \right\}.$$

Seleção do grau via *data splitting*

Queremos selecionar o melhor modelo dentro da classe

$$\Psi = \left\{ \psi_p(\mathbf{x}) = \beta_0 + \sum_{j=1}^p \beta_j x^j, \quad p \in \{1, 2, \dots, P_{\max}\} \right\}.$$

1. Dividir os dados em treinamento, validação e teste (ex: 70%/15%/15%).
2. Para cada p , estimar $\hat{\beta}$ no treinamento e calcular o EQM no conjunto de validação:

$$\frac{1}{n_{\text{val}}} \sum_{i \in \text{val}} (y_i - \hat{\psi}_p(x_i))^2.$$

3. Escolher p^* que minimiza o EQM no conjunto de validação.
4. Reportar o risco estimado de $\hat{\psi}_{p^*}$ no conjunto de teste:

$$\frac{1}{n_{\text{teste}}} \sum_{i \in \text{teste}} (y_i - \hat{\psi}_{p^*}(x_i))^2.$$

Alternativa: validação cruzada (k -fold CV) para os passos 2–3, mantendo o teste intocado.

Modelo correto garante melhores previsões?

Na cultura estatística, verifica-se se as suposições do modelo adotado são satisfeitas.

Modelo correto garante melhores previsões?

Na cultura estatística, verifica-se se as suposições do modelo adotado são satisfeitas.

Especificar o modelo correto garante a melhor performance preditiva possível?

Modelo correto garante melhores previsões?

Na cultura estatística, verifica-se se as suposições do modelo adotado são satisfeitas.

Especificar o modelo correto garante a melhor performance preditiva possível?

Modelo correto garante melhores previsões?

Na cultura estatística, verifica-se se as suposições do modelo adotado são satisfeitas.

Especificar o modelo correto garante a melhor performance preditiva possível?

Não necessariamente! Vejamos um exemplo.

Especificação correta não garante melhor predição!

Geramos $n = 15$ observações com o modelo verdadeiro:

$$Y \mid x \sim \text{Normal}(\beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5, 1),$$

com $\beta = (0, 3, 2, 0,2, 0,1, 0,1)$.

Especificação correta não garante melhor predição!

Geramos $n = 15$ observações com o modelo verdadeiro:

$$Y \mid x \sim \text{Normal}(\beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5, 1),$$

com $\beta = (0, 3, 2, 0,2, 0,1, 0,1)$.

A regressão verdadeira é um polinômio de grau 5.

Especificação correta não garante melhor predição!

Geramos $n = 15$ observações com o modelo verdadeiro:

$$Y \mid x \sim \text{Normal}(\beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5, 1),$$



com $\beta = (0, 3, 2, 0,2, 0,1, 0,1)$.

A regressão verdadeira é um polinômio de grau 5.

Ajustamos dois modelos:

- Polinômio de grau 5 (modelo corretamente especificado).
- Polinômio de grau 2 (modelo incorretamente especificado).

Resultado



- Apesar de o modelo correto ser um polinômio de grau 5, o modelo de grau 2 teve erro de teste muito menor.
- O modelo de grau 2 tem variância muito menor, mesmo sendo viesado. O ganho em variância supera a perda em viés.
- Sob o enfoque preditivista, o que importa é o erro de teste, não a especificação correta do modelo. Estimar mais parâmetros do que o necessário pode ser catastrófico para a predição.
- E se pudéssemos manter o modelo de grau 5, mas “encolher” os coeficientes dos termos menos importantes em direção a zero?

Em predição, é comum abrir mão de um estimador não viesado para, em troca, obter um estimador com variância menor e, assim, erro de teste (risco) menor.

Em predição, é comum abrir mão de um estimador não viesado para, em troca, obter um estimador com variância menor e, assim, erro de teste (risco) menor.

Isso se aplica em todo o restante da disciplina:

- Regularização (Ridge, Lasso): introduzem viés deliberadamente para reduzir a variância.

Em predição, é comum abrir mão de um estimador não viesado para, em troca, obter um estimador com variância menor e, assim, erro de teste (risco) menor.

Isso se aplica em todo o restante da disciplina:

- Regularização (Ridge, Lasso): introduzem viés deliberadamente para reduzir a variância.
- Validação cruzada / data splitting: permitem estimar o risco e escolher a complexidade ótima.

Em predição, é comum abrir mão de um estimador não viesado para, em troca, obter um estimador com variância menor e, assim, erro de teste (risco) menor.

Isso se aplica em todo o restante da disciplina:

- Regularização (Ridge, Lasso): introduzem viés deliberadamente para reduzir a variância.
- Validação cruzada / data splitting: permitem estimar o risco e escolher a complexidade ótima.
- Seleção de variáveis: descartar preditores pode aumentar viés, mas a diminuição da variância frequentemente compensa.

1. O objetivo, sob a ótica preditivista, é encontrar $\hat{\psi}$ com $\mathbb{E}[(Y - \psi(X))^2]$ baixo.

1. O objetivo, sob a ótica preditivista, é encontrar $\hat{\psi}$ com $\mathbb{E}[(Y - \psi(X))^2]$ baixo.

1. O objetivo, sob a ótica preditivista, é encontrar $\hat{\psi}$ com $\mathbb{E}[(Y - \psi(X))^2]$ baixo.
2. Regressão linear: $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{Y}$. Mesmo sob especificação incorreta, OLS converge para o melhor preditor linear β^* .

1. O objetivo, sob a ótica preditivista, é encontrar $\hat{\psi}$ com $\mathbb{E}[(Y - \psi(X))^2]$ baixo.
2. Regressão linear: $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{Y}$. Mesmo sob especificação incorreta, OLS converge para o melhor preditor linear β^* .

1. O objetivo, sob a ótica preditivista, é encontrar $\hat{\psi}$ com $\mathbb{E}[(Y - \psi(X))^2]$ baixo.
2. Regressão linear: $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{Y}$. Mesmo sob especificação incorreta, OLS converge para o melhor preditor linear β^* .
3. Na regressão polinomial, o grau p é um tuning parameter. Escolhemos p via validação cruzada ou *data splitting*.

1. O objetivo, sob a ótica preditivista, é encontrar $\hat{\psi}$ com $\mathbb{E}[(Y - \psi(X))^2]$ baixo.
2. Regressão linear: $\hat{\beta} = (\mathbb{X}^\top \mathbb{X})^{-1} \mathbb{X}^\top \mathbb{Y}$. Mesmo sob especificação incorreta, OLS converge para o melhor preditor linear β^* .
3. Na regressão polinomial, o grau p é um tuning parameter. Escolhemos p via validação cruzada ou *data splitting*.
4. Modelo correto não implica necessariamente em melhor predição. Modelos mais simples podem ter erro de teste menor por terem menor variância.