

Universidade Federal de Sao Carlos (UFSCar)

Departamento de Estatística

MINERACAO DE DADOS

Projeto de Interpretabilidade de Modelos

Projeto Mineração – Grupo 5

Integrantes:

Nome	RA
Arthur Pereira Gon	811464
Giovanni Roberti	811676
Igor Figueiredo	791420
Lucas Yukio	813650
Murilo Cassiavilani	812067

Tema e Modalidade

Tema sorteado: 5 – Interpretabilidade de Modelos. **Modalidade:** A – Projeto aplicado de mineração de dados.

Resumo

Este projeto investiga a interpretabilidade de modelos preditivos aplicada aos cinco paradigmas de modelagem da disciplina. Para cada paradigma, foram selecionados datasets reais, ajustados modelos representativos e aplicadas técnicas específicas de interpretação para responder: por que o modelo prediz o que prediz?

Metodologia

O desenvolvimento foi realizado em Python com scikit-learn para modelagem, utilizando validação cruzada e divisões temporais quando apropriado. As técnicas de interpretabilidade empregadas incluem: coeficientes regularizados (Lasso), importância por permutação, Partial Dependence Plots (PDP) e SHAP (SHapley Additive exPlanations).

Paradigmas Implementados

1. Regressão – Predição de Salários NBA. Dataset: NBA Player Salaries 2022-23 (467 jogadores). Modelos: OLS, Ridge, Lasso, Random Forest. Variável resposta: salário anual (log-transformado). Melhor resultado: Random Forest ($R^2 = 0.71$). Interpretabilidade: coeficientes padronizados revelaram que minutos jogados e Box Plus/Minus são os preditores mais importantes. Fonte: <https://www.kaggle.com/datasets/jamiewelsh2/nba-player-salaries-2022-23-season>.

2. Classificação – Vitória do Mandante na Premier League. Dataset: Premier League Stats 2006-2018 (4.560 partidas). Modelos: Regressão Logística com Lasso, Random Forest. Variável resposta: vitória do mandante (binária). Divisão temporal: treino 2006-2015, teste 2016-2018. Melhor resultado: Logística Lasso (AUC-ROC = 0.77). Interpretabilidade: o Lasso selecionou apenas 3 variáveis (diff_wins, diff_losses, diff_att_ibox_goal), revelando que a forma do time é o único preditor realmente importante. Fonte: <https://www.kaggle.com/datasets/zaemmnalla/premier-league>.

3. Agrupamento – Perfis de Jogadores de Tênis. Dataset: Tennis Player Data (462 jogadores ATP). Algoritmos: K-Means ($K = 2$, escolhido via Silhouette = 0.24) e Agrupamento Hierárquico (Ward). Features: 12 métricas de saque e devolução. Clusters identificados: (0) Saqueadores/Agressivos (42 jogadores, ex: Dimitrov, Hurkacz) e (1) Devolvedores/Baseline (56 jogadores, ex: Carreno Busta, De Minaur). Interpretabilidade: análise dos centroides, gráficos radar e jogadores representativos validam a dicotomia clássica do tênis. Fonte: <https://www.kaggle.com/datasets/mohammadkumail110/tennis-player-data-serve-return-and-raw>.

Paradigmas Pendentes

4. Mineração de Textos: Modelagem de tópicos (LDA) e classificação de documentos, com interpretação por inspeção de palavras relevantes.

5. Detecção de Anomalias: Isolation Forest e LOF, com interpretação das variáveis que mais se desviam do perfil médio.

Implementacao

Desenvolvimento em Python com scikit-learn, pandas, matplotlib e seaborn. Todo o codigo esta organizado em pipelines reprodutíveis, documentando desde a importacao dos dados brutos ate a geracao das figuras e tabelas finais. Repositorio: <https://github.com/ArthurGoon/Projeto-Mineracao-de-Dados>.

Referencias

1. Welsh, J. NBA Player Salaries (2022-23 Season). Kaggle, 2023.
2. Kumail, M. Tennis Player Data (Serve, Return and Raw). Kaggle, 2024.
3. Zaeem, N. Premier League Stats. Kaggle, 2019.
4. Tibshirani, R. Regression Shrinkage and Selection via the Lasso. JRSS, 1996.
5. Breiman, L. Random Forests. Machine Learning, 2001.
6. Lundberg, S. M.; Lee, S. I. A Unified Approach to Interpreting Model Predictions. NeurIPS, 2017.